

**Analyse exploratoire des œuvres et des thèmes
de la littérature russe à partir du dictionnaire de
Jacques Sancer**

Analyse exploratoire des œuvres et des thèmes de la littérature russe à partir du dictionnaire de Jacques Sangan

André MERY



Nuage de mots construit à partir de la fréquence des thèmes dans le corpus étudié.

Présentation de cette étude

L'analyse est effectuée à partir de l'ouvrage intitulé « Dictionnaire des œuvres et des thèmes de la littérature russe », publié par Jacques Sangan chez Classiques Hachette dans la collection « Faire le point » en 1973.

L'ouvrage recense 173 œuvres de 66 auteurs russes du *XVII^e* au *XX^e* siècle, répertoriés selon 65 thèmes. Il est mentionné dans le présent document à chaque fois que nécessaire par l'appellation *Dictionnaire*.

Le matériel à étudier se présente essentiellement comme une matrice œuvres × thèmes à valeurs binaires : la valeur 1 indique qu'un thème est répertorié par le *Dictionnaire* pour une œuvre donnée ; la valeur 0 doit donc être comprise comme une absence de référencement dans le *Dictionnaire*, et non comme une absence certaine du thème dans l'œuvre elle-même.

L'objectif de cette étude est d'examiner si la matrice œuvres × thèmes permet de faire apparaître des régularités : thèmes fréquemment associés, regroupements thématiques, rapprochements entre œuvres ou entre auteurs, et éventuelles structures chronologiques.

L'étude adopte une démarche exploratoire : elle décrit d'abord la structure du corpus, puis mobilise différents outils statistiques et graphiques afin d'examiner les proximités entre thèmes, œuvres et auteurs. Les résultats proposés doivent donc être lus comme des indications de structure interne au corpus codé, et non comme une classification définitive de la littérature russe.




Table des matières

Présentation de cette étude	1
Références	5
Liste des tableaux	5
Liste des figures	5
Liste bibliographique	6
Base de données	7
Le matériel à traiter	7
Compléments au matériel	8
Précisions sur les informations	8
Principes de codage.....	9
Précautions d'interprétation	10
La matrice obtenue	11
Logiciel	11
Description des données	12
Les auteurs	12
Les œuvres	13
Les thèmes	15
Analyse des données	18
Les auteurs	18
La matrice des profils.....	18
Diversité et volume thématique	20
Densité moyenne du profil thématique	21
Normalisation sphérique et dendrogramme des auteurs	23
Analyse en composantes principales	25
Les œuvres	32
Répartition par périodes.....	32
Dendrogramme des œuvres	32
Technique MDS sur les œuvres	34
Les thèmes	36
La matrice des thèmes.....	36
Distance de Jaccard entre thèmes.....	36
Dendrogramme des thèmes	37
Analyse des distances de Jaccard	39
Heatmap des distances de Jaccard	40
Technique MDS sur les thèmes	41
Co-occurrence des thèmes.....	43

Représentation des thèmes en réseau	45
Construction de communautés de thèmes	47
ACP sur les thèmes	48
ACP des thèmes – axes supplémentaires.....	51
Évolution des thèmes par périodes	52
Les thèmes et la rupture de 1917	55
Recherche de clusters	56
Analyse des correspondances entre auteurs et thèmes	58
Construction de la matrice de travail	58
Graphique AC	59
Contributions et carrés du cosinus	59
Points retenus pour l'interprétation	61
Graphique complémentaire	62
Conclusion de cette étude	65
Annexes	67
A1 Logiciels utilisés	67
A2 Nombre d'œuvres contenant un thème donné.....	68
A3 Liste des œuvres du corpus	69
A4 Dendrogramme complet des œuvres du corpus	70
A5 Frise chronologique des auteurs du corpus	72
A6 Technique MDS (Multi-Dimensional Scaling).....	73
A7 Détail de construction de la modularité	74
Construction	74
Résumé.....	77
Précisions	77
A8 Analyse de sensibilité pour le seuil du réseau	78
A9 Matrice finale de profil thématique pour l'AC	81
A10 Contributions et $\cos^2$ en analyse des correspondances	83
Idée essentielle	83
Principe général.....	83
Définition mathématique des contributions	83
Interprétation de la contribution	84
Contribution moyenne attendue.....	84
Contribution au plan factoriel 1-2	84
Définition géométrique du $\cos^2$	85
Valeurs possibles du $\cos^2$	85
$\cos^2$ sur plan factoriel 1 – 2	86
Utilité des $\cos^2$	86

Résumé des combinaisons possibles	87
---	----

Références

Liste des tableaux

Tableau 1 Extrait de la matrice complète de codage œuvres × thèmes :.....	11
Tableau 2 Liste des auteurs du corpus	12
Tableau 3 Liste des thèmes du corpus	15
Tableau 4 Liste des œuvres associées à un thème unique	16
Tableau 5 Coefficients ACP des thèmes sur PC1 et PC2	28
Tableau 6 Coefficients ACP des thèmes sur PC3 et PC4	31
Tableau 7 Choix du n_init (MDS) appliqué aux œuvres	34
Tableau 8 Matrice matrix_themes : premières lignes et premières colonnes.....	36
Tableau 9 Choix du n_init (MDS) appliqué aux thèmes	41
Tableau 10 Extrait de la matrice de co-occurrence des thèmes.....	43
Tableau 11 Choix d'un seuil pour le réseau des thèmes	45
Tableau 12 Communautés de thèmes extraites du réseau (seuil=5)	47
Tableau 13 Identification des thèmes les plus excentrés	50
Tableau 14 Identification des co-occurrences les plus importantes	50
Tableau 15 Auteurs interprétables en AC	61
Tableau 16 Thèmes interprétables en AC	61

Liste des figures

Figure 1 Nombre d'auteurs par périodes semi-séculaires	12
Figure 2 Chronologie des œuvres du corpus.....	13
Figure 3 Nombre d'œuvres par nombre de thèmes	15
Figure 4 Thèmes les plus fréquemment rencontrés dans le corpus	17
Figure 5 Heatmap du profil thématique des auteurs	19
Figure 6 Diversité et volume thématique des auteurs	20
Figure 7 Densité moyenne du profil et dispersion thématique	22
Figure 8 Dendrogramme des auteurs du corpus	24
Figure 9 ACP des auteurs du corpus (variance des composantes).....	26
Figure 10 ACP des auteurs PC1 × PC2	27
Figure 11 ACP des auteurs PC1 × PC2 (avec flèches de thèmes)	29
Figure 12 ACP des auteurs (axes supplémentaires) PC3 × PC4.....	31
Figure 13 Répartition des œuvres par périodes historiques.....	32
Figure 14 Dendrogramme des œuvres (avec troncature).....	33
Figure 15 MDS des œuvres	35
Figure 16 Dendrogramme des thèmes	38
Figure 17 Distance de Jaccard entre thèmes (par rapport à 1)	39
Figure 18 Distance de Jaccard entre thèmes (graphiques divers)	39
Figure 19 Heatmap des distances de Jaccard entre thèmes.....	40
Figure 20 MDS des thèmes	42
Figure 21 Heatmap de co-occurrence des thèmes	44
Figure 22 Réseau des thèmes	46
Figure 23 ACP des thèmes du corpus (variance des composantes)	48
Figure 24 ACP des thèmes PC1 × PC2	49
Figure 25 ACP des thèmes sur les axes 3 et 4.....	51
Figure 26 Heatmap des thèmes par périodes historiques	54
Figure 27 Barplot des thèmes par rapport à 1917.....	56
Figure 28 Recherche d'un clustering des thèmes	57
Figure 29 Analyse des correspondances Auteurs-Thèmes	59

Liste bibliographique

Sancan, Jacques, Dictionnaire des œuvres et des thèmes de la littérature russe, *Paris, Classiques Hachette*, coll. « *Faire le point* », 1973.

Jacques Michaut, Jacques Sancan, De Avvakum à Zinoviev. Anthologie de la littérature russe, *Paris, Librairie du Globe*, 1996.

Matthew L. Jockers, Macroanalysis: Digital Methods and Literary History, *University of Illinois Press*, 2013.

Jolliffe, Cadima, Principal Component Analysis: A Review and Recent Developments, *Philosophical Transactions of the Royal Society A*, 374, 2016.

Kaufman, Rousseeuw, Finding Groups in Data: An Introduction to Cluster Analysis, *Wiley*, 1990.

Borg, Groenen, Modern Multidimensional Scaling: Theory and Applications, *Springer*, 2005.

Pedregosa et al., Scikit-learn: Machine Learning in Python, *Journal of Machine Learning Research*, 12, 2011, p. 2825-2830.

Hagberg, Schult, Swart, Exploring Network Structure, Dynamics, and Function using NetworkX, *Proceedings of the 7th Python in Science Conference*, 2008, p. 11-15.

Waskom, seaborn: statistical data visualization, *Journal of Open Source Software*, 6/60, 2021, article 3021.

scikit-learn developers, “Multidimensional Scaling”, documentation officielle de scikit-learn, [consultée le 1er juillet 2026] :

(<https://scikit-learn.org/stable/modules/generated/sklearn.manifold.MDS.html>)

(<https://scikit-learn.org/stable/modules/generated/sklearn.manifold.smacof.html>).

Ana Isabel Queiroz, Margarida Lopes Fernandes, Filipa Soares, The Portuguese Literary Wolf, *Digital Scholarship in the Humanities*, 30/3, 2015, p. 388-404. DOI : 10.1093/lle/fqt069.

Michael Greenacre, *Correspondence Analysis in Practice*, September 2009, *Biometrics*, Volume 65, Issue 3, September 2009, Pages 997–998, https://doi.org/10.1111/j.1541-0420.2009.01315_11.x

Base de données


Le matériel à traiter

L'ouvrage de Jacques Sançan se compose d'œuvres littéraires russes classées par ordre alphabétique. Pour chaque œuvre, le *Dictionnaire* fournit notamment :

- le titre usuel en français ;
- le titre en russe ;
- le genre ou le type d'œuvre ;
- le nom de l'auteur, dans sa transcription française habituelle ;
- la date ou la période de composition ;
- une indication d'édition française ;
- une notice explicative présentant le contenu de l'œuvre ;
- une liste de thèmes majeurs attribués à l'œuvre.

Les thèmes sont désignés par un mot ou une expression caractéristique, par exemple « Guerre », « Apprentissage », « Héros », etc.

La première page du *Dictionnaire* est reproduite ci-dessous à titre d'exemple, afin de montrer la forme des notices à partir desquelles les données ont été codées :



Compléments au matériel

Précisions sur les informations

• Certaines informations absentes ou incomplètes dans l'ouvrage de 1973 ont été complétées par le rédacteur de ce document pour les besoins de l'analyse :

- Certains auteurs russes n'étant pas décédés à l'époque de l'ouvrage, les dates de décès manquantes ont été rajoutées après consultation de sources biographiques usuelles, principalement Wikipédia.
- Un ouvrage de TOURGUENIEV, *À la veille*, était recensé dans la partie « Table alphabétique des auteurs » mais ne faisait l'objet d'aucune analyse thématique dans le *Dictionnaire*. Les thèmes correspondant à cette œuvre ont donc été récupérés à partir d'un recensement ultérieur d'œuvres littéraires d'auteurs russes « De Avvakum à Zinoviev », publié aux éditions de la Librairie du Globe en 1996. Cette intervention externe au *Dictionnaire* n'a concerné qu'une seule œuvre du corpus.
- Deux thèmes, « Remords » et « Violence », ont été intégrés à la base, bien qu'ils ne figurent pas dans la liste synthétique des thèmes du *Dictionnaire*, car ils apparaissent en marge de certaines œuvres analysées.
- Deux œuvres de Nicolas GOGOL (*Les Soirées du hameau près de Dikanka* et *Mirgorod*), répertoriées chacune dans le *Dictionnaire* sous une seule appellation, faisaient l'objet de comptes rendus séparés en tant que composées de plusieurs récits à thèmes différents ; ces récits ont été individualisés, avec leurs thèmes propres, dans la base de données.
- Le thème noté « Satan », qui n'apparaît que dans une seule œuvre, a été assimilé au thème « Fantastique ».
- Les deux thèmes « Délire » et « Folie » qui apparaissent dans certaines œuvres, ont été rassemblés sous l'appellation « Délire-Folie », en conformité avec le classement dans la liste des thèmes du *Dictionnaire* qui indiquait « Délire (folie) ».

Ces interventions ne modifient pas l'économie générale du corpus, mais elles doivent être signalées car elles introduisent une part limitée de codage externe ou de normalisation éditoriale.

• Il est également à noter que :

- Les deux auteurs Ilia ILF (1897 – 1937) et Evgueni PETROV (1903 – 1942) ont écrit leurs œuvres « à quatre mains » et publié sous le nom collectif de « ILF ET PETROV » ; ils ont été enregistrés comme un auteur unique et les dates de naissance et de décès indiquées correspondent aux dates extrémales pour l'ensemble des deux écrivains...
- Les patronymes identiques NEKRASSOV, OSTROVSKI et TOLSTOÏ se rapportant à des auteurs différents ont été individualisés par les initiales de leurs prénoms, de façon à travailler sur des appellations distinctes :
 - N.NEKRASSOV : pour « Nicolas » NEKRASSOV,
 - V.NEKRASSOV : pour « Victor » NEKRASSOV,
 - A.OSTROVSKI : pour « Alexandre » OSTROVSKI
 - N.OSTROVSKI : pour « Nicolas » OSTROVSKI
 - A.TOLSTOÏ : pour « Alexis » TOLSTOÏ,
 - L.TOLSTOÏ : pour « Léon » (« Lev » en russe) TOLSTOÏ
- L'œuvre que MAÏAKOVSKI a produite en 1921, est appelée en français, selon les cas, *Mistère-Bouffe* ou *Mystère-Bouffe*. On a conservé l'appellation *Mistère-Bouffe* du *Dictionnaire*.

Principes de codage

• Les thèmes sont des catégories éditoriales, attribuées par le rédacteur du *Dictionnaire*, qui ne résultent pas d'une analyse automatique du texte intégral des œuvres :

- une valeur 1 signifie que le thème est explicitement mentionné dans le *Dictionnaire* pour cette œuvre.
- une valeur 0 signifie que le thème n'est pas mentionné dans le *Dictionnaire* pour cette œuvre, mais cela ne signifie pas nécessairement que le thème est absent de l'œuvre au sens littéraire profond.

• Par ailleurs, ont été rajoutées personnellement à la base de données :

- Une date de composition de l'œuvre, notée « Composed », soit celle directement indiquée dans le *Dictionnaire*, soit le point médian de l'intervalle chronologique des deux dates indiquées dans le *Dictionnaire*, si la rédaction a été notée comme étalée sur plusieurs années. La date de composition n'a pas été croisée avec d'autres sources et l'on a considéré comme fiables les dates indiquées dans le *Dictionnaire*.
- Une variable chronologique construite par regroupement des auteurs selon leur date de décès, selon des intervalles semi-séculaires conventionnels, notée « Period », et arbitrairement choisie par le rédacteur de ce document, à savoir :

- < 1800, [1800 – 1850[, [1850 – 1900[, [1900 – 1950[, [1950 – 2000[, ≥ 2000

Ce choix ne constitue pas une périodisation littéraire stricte, mais sert à regrouper les auteurs selon de grands repères temporels, en prenant la date de décès comme « terminus ad quem » de la production littéraire de l'auteur.

- Une autre périodisation, notée « When », envisagée afin de tenir compte de quelques ruptures majeures de l'histoire russe, construite par regroupement des œuvres selon leur date de composition et assortie d'une variable « Name » donnant une interprétation de la période :

« When »	« Name »
< 1800	période ancienne / pré-moderne
[1800 – 1850[	première moitié du <i>XIX^e</i> siècle
[1850 – 1905[	grand <i>XIX^e</i> siècle, réalisme, monde impérial tardif
[1905 – 1917[	crise pré-révolutionnaire
[1917 – 1953[	révolution, guerre civile, stalinisme
[1953 – 1991[	période soviétique post-stalinienne
≥ 1991	période post-soviétique

- Une variable binaire supplémentaire, notée « CutOff », situant la date de composition de l'œuvre par rapport à la révolution russe de 1917, à savoir :
 - ≤ 1917, > 1917

Précautions d'interprétation

On rappelle que :

- Le corpus est construit à partir d'un dictionnaire thématique, non à partir des textes complets. Il reflète les choix d'un ouvrage publié en 1973, complété ponctuellement, et les résultats décrivent donc une représentation structurée de la littérature russe proposée par le *Dictionnaire*, mais non la littérature russe dans son ensemble.
- Les thèmes sont des catégories interprétatives attribuées par le *Dictionnaire*, où la valeur 0 signifie « thème non répertorié », pas nécessairement « thème absent ».
- Les analyses statistiques fournies décrivent les structures internes du corpus codé et les résultats doivent être interprétés comme des indices de proximité ou d'association, non comme des preuves littéraires définitives.

La matrice obtenue

• Le résultat des données brutes du *Dictionnaire* et des modifications ou ajouts effectués par le rédacteur du présent document se présente comme une matrice (nommée dans les programmes `matrix_all_extended`), de taille 173 × 74 contenant :

- 9 colonnes d'identifiants :

['Works', 'Author', 'Birth', 'Death', 'Period', 'Composed', 'When', 'Name', 'CutOff']

- et 65 colonnes de thèmes :

['Amour', 'Apprentissage', ..., 'Violence']

colonnes renseignées par 0 (thème non répertorié pour l'œuvre) ou 1 (thème répertorié dans l'œuvre).

Tableau 1 Extrait de la matrice complète de codage œuvres × thèmes :

matrix_all_extended											
	Works	Author	Birth	Death	Period	Composed	When	Name	CutOff	Amour	...
0	Et l'Acier fut trempé	N.OSTROVSKI	1904	1936	[1900-1950[	1933	[1917-1953[	révolution, guerre civile, stalinisme	>1917	0	...
1	L'Adolescent	DOSTOÏEVSKI	1821	1881	[1850-1900[	1875	[1850-1905[	grand XIXe siècle, réalisme, monde impérial ta...	<=1917	1	...
2	L'Affaire des Artamonov	GORKI	1868	1936	[1900-1950[	1925	[1917-1953[	révolution, guerre civile, stalinisme	>1917	0	...
3	Les Ames mortes	GOGOL	1811	1852	[1850-1900[	1839	[1800-1850[	première moitié du XIXe siècle	<=1917	0	...
4	Anna Karénine	LTOLSTOÏ	1828	1910	[1900-1950[	1875	[1850-1905[	grand XIXe siècle, réalisme, monde impérial ta...	<=1917	1	...
...	...	...	...	...	...	...	...	...	...	...	...

• L'extrait est volontairement tronqué pour des raisons de lisibilité.

Logiciel

Les traitements ont été réalisés en Python, version 3.12.2

Plus d'informations sur l'environnement et les principales bibliothèques utilisées sont fournies dans la partie **Annexe (A1)**.

Description des données

Les auteurs

La liste des 66 auteurs du corpus est donnée ci-dessous, par classement alphabétique de leur appellation :


Tableau 2 Liste des auteurs du corpus

A.OSTROVSKI	BONDARIEV	GORKI	KOUZNETSOV	PANOVA	SINIAVSKI
A.TOLSTOÏ	BOULGAKOV	GRIBOÏEDOV	L.TOLSTOÏ	PAOUSTOVSKI	SOLJENITSYNE
AKSAKOV	BOUNINE	GROSSMAN	LAVRENIOV	PASTERNAK	SOLOGOUB
ANDRÉÏEV	CHOLOKHOV	GUINZBOURG	LEONOV	PLATONOV	TCHEKHOV
AVVAKUM	DOSTOÏEVSKI	HERZEN	LERMONTOV	POGODINE	TCHERNYCHEVSKI
AÏTMATOV	DOUDINTSEV	ILF ET PETROV	LESKOV	POLEVOÏ	TENDRIAKOV
BABEL	FADÉÏEV	KARAMZINE	MAKSIMOV	POUCHKINE	TOURGUENIEV
BECK	FEDINE	KATAÏEV	MAÏAKOVSKI	RADICHTCHEV	TYNIANOV
BERGHOLTS	FONVIZINE	KAZAKOV	MELNIKOV-PETCHERSKI	REMIZOV	V.NEKRASSOV
BIELY	GOGOL	KOROLENKO	N.NEKRASSOV	SALTYKOV-CHTCHEDRINE	VLADIMOV
BLOK	GONTCHAROV	KOUPRINE	N.OSTROVSKI	SIMONOV	ZAMIATINE

Figure 1 Nombre d'auteurs par périodes semi-séculaires

- D'après leur date de décès, les auteurs du corpus se concentrent principalement autour du XX^e siècle : 70% d'entre eux environ (47/66) sont décédés entre 1900 et 2000, et 60% d'entre eux environ (39/66) sont décédés après la révolution de 1917 (parmi lesquels 10 d'entre eux sont nés après 1917 et n'ont donc pas « vécu » cette révolution).

Leur répartition selon la période de décès est représentée ci-contre :



- Par souci d'exhaustivité, une frise chronologique globale des auteurs est donnée dans la partie


Annexe (A5), où les auteurs sont classés par date croissante de décès.

- Cette répartition par date de décès ne vise pas à proposer une périodisation littéraire stricte ; elle sert seulement à donner un aperçu chronologique global des auteurs du corpus.

Les œuvres

- La liste complète des 173 œuvres du corpus est donnée dans la partie **Annexe (A3)**, par classement alphabétique de leur appellation telle qu'enregistrée dans le *Dictionnaire*. La figure suivante présente, pour chaque auteur du corpus, la chronologie des œuvres retenues dans l'étude :

Figure 2 Chronologie des œuvres du corpus



- Les auteurs sont ordonnés selon la date médiane de composition de leurs œuvres. Pour chacun d'eux, le segment horizontal indique l'intervalle compris entre la première et la dernière œuvre présentes dans le corpus, tandis que le point central correspond à la date médiane de composition.

La couleur bleu ou rouge des points médians correspond au positionnement par rapport à 1917.

Une nette progression chronologique apparaît du haut vers le bas du graphique. Les auteurs les plus anciens (AVVAKUM, FONVIZINE, RADICHTCHEV ou KARAMZINE) occupent la partie supérieure, tandis que les écrivains soviétiques et les auteurs les plus récents du corpus se concentrent dans la partie inférieure.

La ligne verticale matérialise l'année 1917, qui constitue un repère historique majeur dans l'histoire russe. La coloration des points médians distingue les auteurs dont la production observée dans le corpus est principalement antérieure à cette date (bleu) de ceux dont elle lui est postérieure (rouge). La transition entre les deux ensembles apparaît progressive plutôt que brutale : plusieurs auteurs, tels que Gorki ou Bounine, se situent à proximité immédiate de la rupture révolutionnaire.

L'étendue des segments varie fortement d'un auteur à l'autre. Certains ne sont représentés que par une seule œuvre, ce qui réduit leur présence à un point unique. D'autres, comme L.TOLSTOÏ, DOSTOÏEVSKI, TOURGUENIEV ou TCHEKHOV, sont associés à plusieurs œuvres couvrant plusieurs décennies, traduisant une représentation plus large de leur trajectoire littéraire au sein du corpus.

Cette visualisation met ainsi en évidence la distribution temporelle des œuvres étudiées et montre que le corpus couvre de manière relativement continue une large période chronologique, allant de la fin du *XVII^e* siècle à la seconde moitié du *XX^e* siècle.

La période post-soviétique, postérieure à 1991, n'est toutefois pas représentée, puisque l'œuvre la plus tardive du corpus date de 1970.

Les thèmes


- La liste des 65 thèmes répertoriés dans le corpus est donnée ci-dessous, par ordre alphabétique :

Tableau 3 Liste des thèmes du corpus

Amour	Dieu	Hypocrisie	Misère	Paysans	Servage
Apprentissage	Délire-Folie	Héros	Mort	Peuple	Socialisme
Argent	Education	Individu	Médiocrité	Pouvoir	Société
Armée	Ennui	Intelligentsia	Nation	Province	Solitude
Art	Fantastique	Jalousie	Nature	Religion	Souffrance
Bonheur	Femme	Jeu	Nihilisme	Remords	Traditions
Campagne	Fonctionnaires	Justice	Noblesse	Responsabilité	Travail
Camps	Guerre	Liberté	Occident	Russie	Vagabondage
Capitalisme	Honneur	Mal	Orgueil	Révolte	Ville
Communisme	Humanisme	Marchands	Paresse	Révolution	Violence
Cosaques	Humiliation	Mariage	Patrie	Rêve	

- Le nombre de thèmes associés à une œuvre varie entre 1 et 10, avec une moyenne de 3.61 thèmes par œuvre, et un écart-type de 1.83 :

Figure 3 Nombre d'œuvres par nombre de thèmes



- À noter que la mention de l'écart-type n'est pas là pour supposer une distribution normale, mais seulement pour donner un repère de dispersion.

- Dix-sept œuvres ne sont associées qu'à un seul thème ; ce sont les suivantes :

Tableau 4 Liste des œuvres associées à un thème unique


Works	Author	Composed	themes
Enfance et Adolescence	L.TOLSTOÏ	1853	['Apprentissage']
L'Eternel mari	DOSTOÏEVSKI	1870	['Amour']
L'Evêque	TCHEKHOV	1902	['Mort']
Le Gel au nez rouge	N.NEKRASOV	1863	['Femme']
Le Grand filon	VLADIMOV	1962	['Travail']
Le Journal d'un fou	GOGOL	1835	['Délire-Folie']
Lady Macbeth du district de Mtsensk	LESKOV	1865	['Amour']
Le Maître et Marguerite	BOULGAKOV	1940	['Fantastique']
Mes Universités	GORKI	1922	['Apprentissage']
Les Petits-bourgeois	GORKI	1901	['Argent']
La Brouille des deux Ivan	GOGOL	1835	['Fonctionnaires']
La Quadrature du cercle	KATAÏEV	1928	['Mariage']
La Salle 6	TCHEKHOV	1862	['Délire-Folie']
Sérioja	PANOVA	1955	['Apprentissage']
La Foire de Sorotchinsky	GOGOL	1832	['Traditions']
La Nuit de Noël	GOGOL	1832	['Fantastique']
Les Yeux tondus	REMIZOV	1957	['Apprentissage']

- D'un autre côté, une seule œuvre est associée à 10 thèmes, ce qui en fait l'œuvre la plus fortement indexée thématiquement dans le corpus : *Guerre et Paix* (L.TOLSTOÏ, 1866), associée aux thèmes suivants :

« Amour »,
« Dieu »,
« Femme »,
« Guerre »,
« Héros »,

« Mort »,
« Nation »,
« Noblesse »,
« Occident »,
« Peuple »

- Les thèmes les plus fréquents sont « Amour » et « Femme », présents respectivement dans 57 et 44 œuvres. Ils apparaissent ainsi comme les deux thèmes les plus fréquemment répertoriés dans le corpus tel qu'il est codé à partir du *Dictionnaire*. Leur association est également fréquente : 27 œuvres contiennent simultanément ces deux thèmes, éventuellement en combinaison avec d'autres.
- Le thème le moins souvent rencontré est « Paresse » (1 œuvre), qui apparaît dans *Oblomov* (GONTCHAROV, 1857) en conjonction avec « Campagne », « Femme » et « Traditions ».
- Le même nuage de mots, utilisé en couverture, est repris ici comme visualisation descriptive des fréquences thématiques :




- On constate que la distribution des fréquences thématiques est très asymétrique. Quelques thèmes concentrent une part importante des occurrences, tandis qu'un grand nombre de thèmes apparaissent dans moins de dix œuvres.

Cette structure justifie de compléter l'analyse des fréquences simples par des analyses de co-occurrence et de proximité : un thème rare peut être peu visible dans les fréquences globales, mais jouer un rôle significatif dans certaines associations thématiques.

- Le graphique qui suit indique les thèmes les plus fréquemment rencontrés (dans au moins 10 œuvres) :

Figure 4 Thèmes les plus fréquemment rencontrés dans le corpus



- Les thèmes les plus fréquemment rencontrés sont :

« Amour », « Femme », « Guerre », « Mort », « Argent »

- Toutefois, aucune œuvre ne contient simultanément ces cinq thèmes, ce qui montre que les fréquences individuelles ne suffisent pas à décrire les associations thématiques...
- Si l'on calcule la fréquence moyenne des 65 thèmes, on constate qu'un thème apparaît en moyenne dans une dizaine d'œuvres (~ 9.60), avec un écart-type à peu près aussi grand (~ 9.05).

- Le graphique complet du nombre d'œuvres contenant un thème donné est fourni dans la partie **Annexe (A2)**.

Analyse des données

Les auteurs

La matrice des profils

- À partir de la base de données générale, on a calculé un profil thématique par auteur :
 - en regroupant toutes les lignes de thèmes qui appartiennent à un même auteur,
 - en appliquant pour chaque thème une somme en colonne à l'intérieur de chaque groupe de lignes appartenant à un même auteur.

Le résultat est alors une matrice auteurs $\times$ thèmes où chaque case contient :

$$n_{ij} = \text{nombre d'œuvres de l'auteur } i \text{ contenant le thème } j$$

Ainsi :

- $n_{ij} = 0 \rightarrow$ le thème j n'est jamais présent chez l'auteur i
- $n_{ij} = 1 \rightarrow$ le thème j est présent dans une seule œuvre chez l'auteur i
- $n_{ij} = 5 \rightarrow$ le thème j est présent dans 5 œuvres de l'auteur i
- etc.


La matrice ainsi générée, `matrix_author_profile`, constitue un véritable « profil thématique » des auteurs, permettant quand cela est nécessaire :

- de comparer les auteurs entre eux,
- de calculer des distances entre auteurs,
- de faire du clustering d'auteurs,
- de construire des réseaux d'auteurs,
- de projeter les auteurs dans une ACP/AC,
- etc.

- Le résultat obtenu a été visualisé à l'aide de la fonction `heatmap` du package `seaborn` dont le graphique est présenté ci-dessous.

Cette heatmap a surtout une fonction diagnostique : elle permet de visualiser la rareté des occurrences non nulles et les différences de densité entre auteurs.

Figure 5 Heatmap du profil thématique des auteurs



- La heatmap présente la matrice brute des profils thématiques des auteurs. Chaque ligne correspond à un auteur, chaque colonne à un thème, et chaque cellule indique le nombre d'œuvres de l'auteur dans lesquelles le thème considéré est présent.

Le graphique n'a pas vocation à permettre une lecture précise cellule par cellule, mais à donner une vue d'ensemble de la densité de la matrice.

Cette représentation permet d'obtenir une première vue d'ensemble de la structure des données. Elle met en évidence le caractère très clairsemé de la matrice : pour la majorité des couples auteur-thème, la valeur est nulle. Elle montre également de fortes différences entre auteurs. Certains profils sont très denses, parce qu'ils reposent sur un nombre important d'œuvres et mobilisent de nombreux thèmes ; d'autres sont beaucoup plus restreints, avec seulement quelques thèmes présents.

Il convient toutefois d'interpréter cette figure comme une visualisation descriptive des données brutes. Les auteurs les plus représentés dans le corpus ont mécaniquement davantage d'occasions de cumuler des occurrences thématiques. La heatmap ne mesure donc pas directement une proximité entre auteurs, mais fournit un état initial de la distribution des thèmes dans le corpus.

Diversité et volume thématique


• On peut alors quantifier un « volume thématique » et une « diversité thématique », en calculant par auteur :

- Le nombre total d'occurrences thématiques dans l'ensemble des œuvres de l'auteur (« volume thématique »), un même thème pouvant être compté plusieurs fois chez un auteur dans des œuvres différentes.
- Le nombre de thèmes distincts répertoriés au moins une fois chez l'auteur (« diversité thématique »)

Le graphique suivant présente le résultat de cette analyse, où chaque point représente un auteur.

Le tableau incrusté indique les douze auteurs ayant le volume thématique total le plus élevé ; la colonne « différents » permet de comparer ce volume à la diversité effective du profil.

Figure 6 Diversité et volume thématique des auteurs



- Ce graphique croise deux indicateurs complémentaires calculés pour chaque auteur. L'axe horizontal représente le nombre de thèmes différents rencontrés dans l'ensemble des œuvres de l'auteur. Il mesure la diversité thématique au sens strict. L'axe vertical représente le nombre total d'occurrences thématiques, c'est-à-dire la somme des présences de thèmes dans les œuvres de l'auteur. Il mesure plutôt le volume ou l'intensité globale du profil thématique.

La relation croissante observée entre les deux axes est attendue : plus un auteur est représenté par un grand nombre d'œuvres dans le corpus, plus il est susceptible de présenter à la fois un volume thématique élevé et un grand nombre de thèmes différents. Le graphique permet cependant de distinguer deux situations : des auteurs qui présentent une grande variété de thèmes différents, et des auteurs dont certains thèmes sont plus fortement répétés dans plusieurs œuvres.

Ainsi, les auteurs situés dans la partie supérieure droite du graphique disposent des profils les plus riches dans le corpus étudié. Leur position ne doit pas être interprétée comme une mesure de valeur littéraire ou d'importance historique, mais comme l'effet combiné de l'étendue du corpus retenu pour chaque auteur et de la variété des thèmes qui y sont associés.

Densité moyenne du profil thématique

- Une autre façon de caractériser les profils thématiques des auteurs est de calculer, pour chacun d'eux, la moyenne et l'écart-type des 65 valeurs de son profil.

Ce calcul mesure donc une « densité moyenne » du profil thématique, complétée par une mesure de dispersion/concentration entre thèmes ; ce n'est pas une diversité pure.

Un graphique a été réalisé pour présenter le résultat de cette analyse. Il est présenté après le paragraphe suivant.


- Le graphique présente, pour chaque auteur, la moyenne et l'écart-type des valeurs de son profil thématique sur l'ensemble des 65 thèmes. La moyenne correspond à la densité globale du profil : elle augmente lorsque l'auteur cumule un nombre important d'occurrences thématiques. L'écart-type indique la dispersion de ces occurrences entre les thèmes : un écart-type élevé signifie que certains thèmes sont beaucoup plus présents que d'autres dans le profil de l'auteur.

Ce graphique ne mesure donc pas seulement la diversité thématique. Il renseigne plutôt sur la combinaison entre intensité globale et concentration du profil. Un auteur peut avoir une moyenne élevée parce qu'il est très représenté dans le corpus, tandis qu'un écart-type important signale que son profil est structuré autour de quelques thèmes particulièrement fréquents.

La lecture conjointe de la moyenne et de l'écart-type complète donc le graphique précédent : elle permet de distinguer les profils thématiquement abondants mais relativement dispersés, des profils plus concentrés autour de quelques orientations dominantes.

- Les segments horizontaux représentent la moyenne $\pm$ un écart-type ; ils ne doivent pas être lus comme un intervalle de confiance ni comme une plage de valeurs théoriquement possibles, mais seulement comme un repère descriptif de dispersion.

Figure 7 Densité moyenne du profil et dispersion thématique



Normalisation sphérique et dendrogramme des auteurs

- Enfin, pour visualiser les proximités entre auteurs, un dendrogramme a été utilisé, en utilisant la métrique cosinus et la méthode average.
- Chaque auteur est représenté par une ligne de la matrice des profils thématiques, `matrix_author_profile`, c'est-à-dire qu'il correspond à un vecteur à 65 éléments :

$$x_i = (n_{i1}, n_{i2}, \dots, n_{i65})$$

Où n_{ij} = nombre d'œuvres de l'auteur i contenant le thème j

Chaque auteur est donc assimilable à un vecteur dans un espace $\mathbb{R}^{65}$ à 65 dimensions.

- La métrique cosinus calcule la « distance cosinus » entre deux auteurs x_i et x_j :

$$d_{cos}(x_i, x_j) = 1 - \frac{x_i \cdot x_j}{\|x_i\| \times \|x_j\|}$$

où le point ($\cdot$) désigne le produit scalaire euclidien usuel entre deux vecteurs et la norme $\| \cdot \|$ désigne la norme euclidienne usuelle d'un vecteur.

La distance cosinus consiste à normaliser les vecteurs à l'unité ($x_i \rightarrow x_i / \|x_i\|$), donc à ramener les extrémités de ces vecteurs sur la sphère unité :

$$S^{64} \subset \mathbb{R}^{65}$$

A ce moment-là, la longueur du vecteur (c'est-à-dire le volume thématique de l'auteur) disparaît et la seule chose qui différencie les auteurs est leur direction thématique :

- deux auteurs proches sur la sphère ont des profils similaires
- deux auteurs éloignés ont des profils très différents ou faiblement recouvrants
- Cette normalisation sphérique a été privilégiée car les variables sont des thèmes littéraires et l'on s'intéresse surtout à savoir quels auteurs ont des orientations thématiques semblables, indépendamment du nombre de thèmes utilisés, qui est fonction du nombre d'œuvres prises en compte pour cet auteur.


- La construction du dendrogramme est basée sur le principe du « clustering hiérarchique agglomératif » où :

- Initialement :
 - ✓ chaque auteur x_i est considéré comme un cluster
 - ✓ il y a autant de clusters que d'auteurs
 - ✓ on trouve les 2 clusters x_i et x_j les plus proches (pour la distance cosinus)
 - ✓ on fusionne ces deux clusters : on les reconsidère comme un seul cluster, soit A
- Itérativement :
 - ✓ on met à jour les distances entre deux clusters C_1 et C_2 par la méthode average :

$$d_{cos}(C_1, C_2) = \frac{1}{Card(C_1) \times Card(C_2)} \sum_{\substack{x_k \in C_1 \\ x_l \in C_2}} d_{cos}(x_k, x_l)$$

- ✓ on trouve à nouveau les 2 clusters les plus proches et on recommence jusqu'à n'avoir plus qu'un seul cluster.

Figure 8 Dendrogramme des auteurs du corpus



- Le dendrogramme représente une classification hiérarchique des auteurs à partir de leurs profils thématiques.

La distance utilisée est la distance cosinus (cosine), qui compare les orientations thématiques des auteurs indépendamment du volume global de leur profil. Deux auteurs sont donc rapprochés lorsqu'ils présentent des répartitions thématiques similaires, même si le nombre total d'occurrences thématiques diffère.

La méthode de liaison moyenne (average) permet de fusionner progressivement les auteurs ou groupes d'auteurs les plus proches, jusqu'à obtenir une structure hiérarchique complète. Les branches courtes signalent des proximités fortes entre profils, tandis que les fusions intervenant à des distances plus élevées correspondent à des regroupements plus généraux et moins homogènes.

Ce graphique doit être lu comme une représentation exploratoire des proximités thématiques. Il suggère des regroupements possibles, mais ne constitue pas à lui seul une classification définitive. Le choix d'un seuil de coupure dans le dendrogramme, ainsi que l'interprétation littéraire des groupes obtenus, doivent faire l'objet d'une analyse complémentaire.

Aucun découpage en groupes d'auteurs n'est retenu ici comme résultat principal ; le dendrogramme est utilisé comme outil de visualisation des proximités globales.

Analyse en composantes principales

Méthodologie

- Une ACP a été réalisée à partir de la matrice `matrix_author_profile`, après une normalisation sphérique des données. Pour chaque ligne correspondant à un auteur i :

$$x_i = (n_{i1}, n_{i2}, \dots, n_{i65})$$

- on a calculé la somme des carrés des valeurs thématiques de cet auteur :

$$s = \sum_{j=1}^{65} n_{ij}^2$$

- puis on a normalisé les valeurs par la racine carrée de cette somme :

$$x_i \rightarrow x_i^* = \left(\frac{n_{i1}}{\sqrt{s}}, \frac{n_{i2}}{\sqrt{s}}, \dots, \frac{n_{i65}}{\sqrt{s}} \right)$$

Les points x_i^* correspondant aux extrémités des vecteurs des auteurs sont ainsi situés sur une sphère de rayon 1.

- Dans sa forme usuelle, une ACP commence par centrer le nuage de points autour du barycentre des valeurs sur lesquelles elle agit ; ici, avec 66 auteurs :

$$\bar{x}^* = \frac{1}{66} \sum_{i=1}^{66} x_i^*$$

Ensuite l'ACP étudie les écarts :

$$e_i^* = x_i^* - \bar{x}^*$$

Autrement dit, l'ACP ne travaille pas sur la sphère elle-même mais sur le nuage de points centré. Après centrage, les points e_i^* ne sont plus sur la sphère et l'ACP cherche le plan qui explique le mieux la dispersion des points observés.


Les variances expliquées

- Pour la matrice `matrix_author_profile`, dont les dimensions sont 66 (auteurs) $\times$ 65 (thèmes), le nombre maximum de composantes calculables est :

$$\min(\text{auteurs} - 1, \text{thèmes}) = \min(65, 65) = 65$$

Les variances expliquées par les composantes ont été calculées et visualisées sur le graphique ci-dessous, où l'on note que les quatre premiers axes expliquent à eux seuls environ $\frac{1}{3}$ de la variance totale :

Figure 9 ACP des auteurs du corpus (variance des composantes)



- Le graphique de variance expliquée montre comment l'information contenue dans les profils thématiques se répartit entre les différentes composantes principales. Les premières composantes concentrent une part plus importante de la variance, mais la décroissance est progressive : l'information n'est pas résumée par un très petit nombre d'axes.

Les quatre premiers axes représentent environ un tiers de la variance totale. Ce résultat indique que l'ACP met en évidence quelques grandes directions de variation, mais qu'une part importante de la structure thématique reste distribuée sur les dimensions suivantes. L'analyse du plan factoriel formé par les deux premiers axes doit donc être interprétée comme une synthèse partielle, et non comme une représentation complète des profils d'auteurs.

ACP sur les axes PC1 et PC2

- Pour une ACP à deux composantes, l'axe 1 constituera la principale opposition de directions thématiques entre auteurs et l'axe 2, perpendiculaire, constituera la seconde opposition indépendante.

L'ACP sur les deux premiers axes est présentée dans le graphique ci-dessous :

Le sous-titre précise que l'ACP est réalisée sans `StandardScaler`, car ce choix est méthodologiquement important.


- (`StandardScaler` est une fonction du module `Scikit-learn` qui standardise les données en rendant la moyenne égale à 0 et la variance égale à 1).

En effet, l'analyse en composantes principales (ACP) a été réalisée sur les profils thématiques après normalisation sphérique, afin de comparer les orientations thématiques relatives des auteurs indépendamment de leur volume thématique global (indépendamment du nombre d'œuvres attribuées à chaque auteur).

Dans ce cadre, comme les profils d'auteurs ont déjà été normalisés par leur norme euclidienne, chaque auteur est représenté par un vecteur de longueur 1. Cette transformation neutralise les différences de volume entre auteurs et permet de comparer la forme relative de leurs profils thématiques.

L'ajout de `StandardScaler` n'est donc pas nécessaire : il modifierait le poids relatif des thèmes en fonction de leur variance entre auteurs, ce qui changerait l'interprétation de l'ACP.

Figure 10 ACP des auteurs PC1 × PC2



• Les deux premiers axes expliquent respectivement 11.6 % et 8.2 % de la variance, soit 19.8 % de la variance totale.

- Le plan factoriel met en évidence une zone centrale dans laquelle se concentrent de nombreux auteurs, dont les profils thématiques apparaissent relativement proches dans l'espace considéré, indiquant que beaucoup d'auteurs ne se distinguent pas fortement selon les principales oppositions thématiques résumées par les deux premiers axes.
- À l'inverse, les auteurs situés en périphérie du plan se distinguent davantage sur les deux axes représentés, traduisant des combinaisons thématiques plus spécifiques au sein du corpus étudié : leur profil présente des coordonnées plus marquées dans ce plan. Leur contribution exacte à la construction des axes doit cependant être évaluée séparément.
- La distance à l'origine, représentée par la couleur des points, fournit une mesure visuelle de leur éloignement dans le plan $PC1 - PC2$; elle ne mesure ni leur contribution exacte ni leur qualité de représentation.

- Il faut toutefois rester prudent et cette représentation ne doit pas être interprétée comme une classification stricte des auteurs :

- Un auteur proche de l'origine n'est pas nécessairement « moyen » ou « peu intéressant » : cela signifie surtout que son profil n'est pas fortement différencié par les deux axes représentés.
- De même, la proximité entre deux auteurs sur ce plan ne garantit pas une proximité globale sur l'ensemble des 65 dimensions.
- Compte tenu de la faible part de variance expliquée par les deux premiers axes, le graphique constitue donc une synthèse visuelle utile des principales oppositions thématiques présentes dans le corpus, mais il ne remplace pas l'analyse complète des distances ou du dendrogramme.
- Une part importante de la variabilité demeure répartie sur les dimensions suivantes.

Tableau des thèmes dominants dans PC1 × PC2

- Dans l'ACP précédente, les points projetés sur les axes PC1 et PC2 sont les auteurs. Les thèmes sont les variables qui ont servi à construire les axes.

Comme les axes sont des combinaisons linéaires des thèmes, chaque thème peut être représenté dans le plan factoriel à partir de ses coefficients dans les composantes principales. On indique ci-dessous les thèmes dont les coefficients présentent les valeurs absolues les plus élevées sur les axes PC1 et PC2 :

Tableau 5 Coefficients ACP des thèmes sur PC1 et PC2

	PC1	PC2	Distance à l'origine
Guerre	0.567348	0.375260	0.680223
Amour	-0.344241	0.543912	0.643694
Femme	-0.291620	0.441474	0.529095
Apprentissage	0.058597	-0.458485	0.462215
Patrie	0.383098	0.125168	0.403028
Communisme	0.279994	0.108587	0.300313
Société	0.194582	-0.045295	0.199784
Héros	0.189783	0.044194	0.194861
Traditions	-0.141339	-0.128545	0.191052
Noblesse	-0.164020	-0.072712	0.179415

ACP avec flèches de thèmes


- Il est donc possible de projeter les coefficients des thèmes sur l'ACP des auteurs, mais pas en tant que points, en tant que flèches représentant des directions partant de l'origine, avec l'interprétation prudente suivante :

« si tel groupe d’auteurs se projette dans la direction de certains thèmes, cela suggère que ces thèmes contribuent à caractériser cette région du plan factoriel, c’est-à-dire que la position du groupe d’auteurs sur le plan factoriel est associée à une valeur relativement forte de ces thèmes, par rapport aux autres auteurs »

En effet, la proximité visuelle auteur-thème est délicate à interpréter, car les auteurs et les thèmes ne sont pas des objets de même nature dans l'ACP.

- Le graphique obtenu est présenté ci-dessous :

Figure 11 ACP des auteurs PC1 $\times$ PC2 (avec flèches de thèmes)



- Les flèches indiquent les directions thématiques qui structurent les axes et représentent les thèmes qui contribuent le plus aux deux premières composantes principales. Elles doivent être interprétées comme une indication des directions thématiques qui structurent les deux premiers axes, et non comme des points comparables aux auteurs.

Les flèches les plus longues correspondent aux thèmes dont les coefficients combinés sur *PC1* et *PC2* sont les plus élevés. Ces thèmes participent donc plus directement à l'interprétation du premier plan, sans que cette longueur constitue à elle seule une mesure de $\cos^2$ (qui mesure la qualité de représentation d'un point sur un axe factoriel ; voir partie **Annexe (A10)**).

En effet, pour interpréter les deux premières composantes, on examine les coefficients des thèmes dans les vecteurs propres associés aux axes *PC1* et *PC2*. Les thèmes dont les coefficients sont les plus élevés en valeur absolue sont ceux qui contribuent le plus à l'orientation de l'axe. Les auteurs situés dans une même région du plan factoriel peuvent donc être rapprochés non pas directement de points-thèmes, mais de directions thématiques dominantes :

- Un auteur situé dans la direction d'une flèche présente, relativement aux autres auteurs, une association plus marquée avec le thème correspondant dans son profil.
- À l'inverse, deux auteurs proches d'une même direction thématique peuvent partager une orientation commune selon les deux premiers axes.
- La proximité visuelle entre un auteur et l'extrémité d'une flèche doit cependant être interprétée avec prudence : les auteurs et les thèmes ne sont pas des objets de même nature dans l'ACP, et les distances auteur-thème n'ont pas le même statut que les distances entre auteurs.

• Le graphique permet surtout d'interpréter les axes :

- L'axe *PC1* oppose notamment des directions associées à certains thèmes situés à droite du plan à des directions situées à gauche.
 - Il distingue principalement, du côté positif de *PC1*, des profils davantage orientés vers la guerre, la patrie, le communisme, la société ou les héros et, du côté négatif, des profils davantage associés à l'amour, à la figure féminine, aux traditions et à la noblesse.
 - Cette opposition doit toutefois être interprétée comme une tendance, et non comme une séparation nette entre deux familles homogènes d'auteurs.
- L'axe *PC2* distingue quant à lui des orientations thématiques plus hautes ou plus basses dans le graphique. Il ne correspond pas à une opposition thématique simple.
 - Il semble plutôt isoler, dans sa partie supérieure, des auteurs marqués par des thèmes fortement différenciateurs tels que l'amour, la figure féminine ou la guerre, tandis que sa partie inférieure renvoie davantage à des profils associés à l'apprentissage, aux traditions ou à la noblesse.
 - L'axe 2 doit donc être compris comme un axe de différenciation secondaire, moins directement interprétable sur le plan littéraire.

ACP sur les axes PC3 et PC4

- Les axes *PC3* et *PC4* ont été examinés par prudence, mais ne révèlent pas de structure interprétable supplémentaire.
- Comme les axes sont des combinaisons linéaires des thèmes, chaque thème peut recevoir une coordonnée sur ces axes sous forme de variable supplémentaire.

On indique ci-dessous les thèmes dont les coefficients présentent les valeurs absolues les plus élevées sur les axes *PC3* et *PC4* :


Tableau 6 Coefficients ACP des thèmes sur PC3 et PC4

	PC3	PC4	distance à l'origine
Apprentissage	-0.528980	0.419443	0.675094
Femme	0.210425	0.572734	0.610166
Société	0.530075	0.034845	0.531219
Fantastique	0.066460	-0.399692	0.405180
Amour	-0.310508	-0.241535	0.393388
Nature	-0.255677	0.023589	0.256762
Noblesse	-0.065918	-0.220628	0.230265
Médiocrité	0.204176	-0.066490	0.214729
Guerre	-0.194905	0.016492	0.195602
Occident	-0.026770	-0.184044	0.185981

• Le graphique est fourni ci-dessous à titre indicatif :

- Les axes 3 et 4 expliquent respectivement 7.0 % et 6.7 % de la variance. Ils représentent donc des dimensions secondaires, moins importantes que les deux premiers axes mais non négligeables.
- Le graphique montre une dispersion plus difficile à interpréter directement. Contrairement au plan *PC1 – PC2*, aucune organisation simple ne se dégage immédiatement.
- Cette représentation constitue une vérification complémentaire : elle montre que la variabilité se poursuit sur les axes suivants, mais sans faire apparaître d'opposition suffisamment nette et stable pour soutenir une interprétation littéraire précise.

Figure 12 ACP des auteurs (axes supplémentaires) PC3 × PC4



Les œuvres

Répartition par périodes

- Le *Dictionnaire* ayant été édité en 1973, l'œuvre la plus tardive enregistrée dans le corpus est : *Il est un blanc navire* (AÏTMATOV, 1970).

La catégorie chronologique la plus représentée du corpus, avec 64 œuvres), appartient à la période « grand *XIX^e* siècle, réalisme, monde impérial tardif » ([1850 – 1905[), que l'on peut requalifier de « classique ». La période de « crise pré-révolutionnaire » ne contient que 9 œuvres. Ce faible effectif peut s'expliquer à la fois par la courte durée de cette période, douze ans, et par les choix de sélection du Dictionnaire.


Toutefois la période soviétique (entre 1917 et 1991) équilibre la période « classique » avec 64 œuvres également, bien que la période « soviétique » étudiée ici ne couvre pas tout l'intervalle 1917 – 1991 en pratique, puisque le corpus s'arrête en 1970.

L'ensemble des deux périodes soviétiques représentées dans le corpus ([1917 – 1953[et [1953 – 1991[) rassemble également 64 œuvres. Il équilibre ainsi numériquement la période [1850 – 1905[, bien que le corpus ne couvre en pratique la période soviétique que jusqu'en 1970.

Au final, le corpus comprend près des deux tiers d'œuvres composées jusqu'en 1917 inclus, et un peu plus d'un tiers après cette date (109 contre 64).

Un graphique résumant la répartition des œuvres par périodes historiques est donné ci-dessous :

Figure 13 Répartition des œuvres par périodes historiques



Dendrogramme des œuvres

- Un dendrogramme a été réalisé pour visualiser les relations entre les œuvres, en utilisant la fonction dendrogram du package *scipy*.

Le dendrogramme complet des œuvres étant difficilement lisible en raison du nombre élevé d'observations, une version tronquée a été utilisée, par le choix dans la fonction dendrogram de l'option `truncate_mode="lastp"` et du paramètre `p=30`.


- l'option `truncate_mode="lastp"` permet de ne conserver que les derniers regroupements de l'arbre hiérarchique, c'est-à-dire les regroupements les plus synthétiques.
- le paramètre `p=30` indique que le dendrogramme est affiché sous la forme de 30 feuilles terminales visibles. Ces feuilles peuvent correspondre soit à des œuvres individuelles, soit à des groupes d'œuvres déjà fusionnées dans les niveaux inférieurs de l'arbre.

Sur le graphique du dendrogramme, les nombres entre parenthèses, par exemple (4) ou (8), indiquent alors le nombre d'œuvres contenues dans un groupe condensé.

Cette représentation ne modifie donc pas le calcul du clustering : elle simplifie seulement l'affichage afin de rendre lisible la structure générale des proximités thématiques entre œuvres.

- Le dendrogramme condensé est donné ci-dessous et le graphique complet est fourni par souci d'exhaustivité dans la partie **Annexe (A4)**. Il est à noter qu'avec des œuvres codées par peu de thèmes, la distance de Jaccard peut produire beaucoup de distances égales à 1. Le dendrogramme des œuvres est donc utile comme visualisation exploratoire, mais fragile pour une classification fine des œuvres.

Figure 14 Dendrogramme des œuvres (avec troncature)



Technique MDS sur les œuvres

- La technique MDS (*Multi – Dimensional Scaling*) a été appliquée à la matrice des distances de Jaccard entre œuvres, fournie à scikit-learn sous forme pré-calculée avec l'option `metric="precomputed"`.

La MDS représente les œuvres (ou les thèmes) dans un espace à deux dimensions en cherchant à préserver au mieux les distances de dissimilarité de Jaccard calculées entre eux, de sorte que les points proches correspondent à des profils thématiques semblables et les points éloignés à des profils différents.

➤ Elle est détaillée de façon plus approfondie dans la partie **Annexe (A6)**.

La projection MDS permet de visualiser les proximités entre œuvres selon leurs combinaisons thématiques. Les regroupements doivent être interprétés avec prudence : ils ne constituent pas une classification littéraire définitive, mais une représentation exploratoire des ressemblances thématiques au sein du corpus.

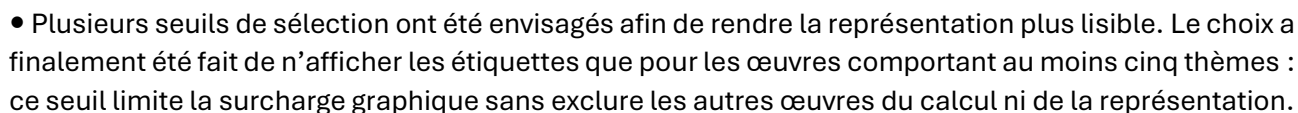
- Plusieurs valeurs de `n_init` ont été testées. Le choix de `n_init = 64` constitue un compromis entre stabilité de la solution et temps de calcul. Des valeurs plus élevées diminuent encore légèrement le stress, mais sans modifier substantiellement l'objectif exploratoire de la représentation :

Tableau 7 Choix du `n_init` (MDS) appliqué aux œuvres

n_init	stress	temps_secondes
1	2017.629	2.070214
2	1956.292	1.721961
4	1956.292	1.976418
8	1956.292	1.849380
16	1955.202	0.746763
32	1955.202	1.434529
64	1942.837	2.956720
128	1942.837	6.152895
256	1942.837	12.485143
512	1931.670	25.587115
1024	1931.670	55.135020

- Les valeurs de stress servent ici uniquement à comparer plusieurs initialisations du même MDS ; elles ne doivent pas être comparées directement aux valeurs obtenues pour le MDS des thèmes.
- Pour éviter une surcharge graphique, tous les points ont été conservés avant de calculer la MDS, mais les labels n'ont été affichés que pour les œuvres ayant au moins 5 thèmes. Le graphique obtenu est donné ci-dessous :

Projection 2D des oeuvres (étiquettes affichées : oeuvres ayant au moins 5 thèmes)
 (métrique : 'Jaccard - precomputed' / initialisation : 'random')
 - coloration par nombre de thèmes dans l'oeuvre -



35

Les thèmes

La matrice des thèmes

• À partir de la base de données générale, on a éliminé les colonnes d'identifiants et construit la matrice des thèmes de taille 173×65 où :

- les 65 colonnes de thèmes sont labellisées par ordre alphabétique (« Amour », « Apprentissage », ..., « Violence »)
- les 173 lignes correspondent aux œuvres du corpus
- les cellules contiennent 0 si le thème n'est pas répertorié dans l'œuvre et 1 si le thème est répertorié

La matrice ainsi générée, `matrix_themes`, permet quand cela est nécessaire :

- de comparer les thèmes entre eux,
- de calculer des distances entre thèmes,
- de faire du clustering de thèmes,
- de construire des réseaux de thèmes,
- de projeter les thèmes dans une ACP/AC,
- etc.

Par souci de contrôle, les premières lignes et colonnes sont présentées dans le tableau ci-dessous :

Tableau 8 Matrice `matrix_themes` : premières lignes et premières colonnes

Amour	Apprentissage	Argent	Armée	Art	Bonheur	Campagne	...
0	1	0	0	0	0	0	
1	1	1	0	0	0	0	
0	0	1	0	0	0	0	
0	0	1	0	0	0	0	
1	0	0	0	0	1	0	

Distance de Jaccard entre thèmes

La matrice `matrix_themes` est d'abord transposée de façon à ce que chaque thème soit décrit – en ligne – par sa présence/absence dans les œuvres.

La distance de Jaccard entre deux ensembles A, B est définie par :

$$d_J(A, B) = 1 - \frac{\text{Card}(A \cap B)}{\text{Card}(A \cup B)}$$

Dans le cas où ces deux ensembles sont des thèmes définis par des attributs binaires (0 / 1), la distance de Jaccard est une mesure très employée du « chevauchement » que A et B partagent au niveau de leurs attributs. Dans ce cas :

- on applique pour évaluer $A \cap B$ et $A \cup B$ les règles de multiplication et d'addition booléennes où, en particulier :

$$1 + 1 = 1$$

Par exemple :

$$\begin{matrix} A = (1,1,0,0) \\ B = (1,0,1,0) \end{matrix} \Rightarrow \begin{matrix} A \cap B = (1,0,0,0) \\ A \cup B = (1,1,1,0) \end{matrix}$$

- ensuite :

- $\Rightarrow \text{Card}(A \cap B)$ est le nombre d'attributs valant 1 dans A et dans B
- $\Rightarrow \text{Card}(A \cup B)$ est le nombre d'attributs valant 1 dans A ou dans B

Par exemple :

$$\begin{matrix} A = (1,1,0,0) \\ B = (1,0,1,0) \end{matrix} \Rightarrow \begin{matrix} \text{Card}(A \cap B) = 1 \\ \text{Card}(A \cup B) = 3 \end{matrix} \Rightarrow d_J(A, B) = 1 - \frac{1}{3} = \frac{2}{3}$$

Par conséquent :

- $d_J = 0 \Leftrightarrow \text{Card}(A \cap B) = \text{Card}(A \cup B)$: il y a autant de 1 dans A et B que dans A ou B ; autrement dit, les deux thèmes apparaissent exactement dans les mêmes œuvres du corpus ; par conséquent, dans l'univers fixé des œuvres étudiées, ils sont aussi absents des mêmes œuvres, ce que l'on peut résumer – sous le terme « co-présents » – par :

« A et B sont totalement co-présents »

- $0 < d_J < 1$: les deux thèmes co-apparaissent dans au moins une œuvre, mais chacun possède aussi des occurrences non partagées avec l'autre. Il y a donc recouvrement partiel de leurs présences dans le corpus, ce que l'on peut résumer par :

« A et B sont partiellement co-présents »

- $d_J = 1 \Leftrightarrow \text{Card}(A \cap B) = 0$: les deux thèmes ne sont jamais présents ensemble dans les œuvres du corpus, ce que l'on peut résumer par :

« A et B n'ont aucune co-présence »


Dendrogramme des thèmes

- Sur la transposée de `matrix_themes`, on a appliqué la fonction `pdist` du package `SciPy` de Python, qui travaille sur des observations en ligne, en utilisant la métrique « jaccard ».

Les 65 thèmes, comparés deux à deux, ont produit $\binom{65}{2} = 2080$ valeurs de distances d_J ($0 \leq d_J \leq 1$), stockées dans un tableau 1D de type `numpy.ndarray` de dimension (2080,) auquel on a appliqué la routine `linkage` du package `SciPy`, en utilisant la méthode de calcul « average » ; cette opération fournit un tableau 2D de type `numpy.ndarray` de dimension (64, 4), sur lequel est appliquée la routine de construction `dendrogram` du package `SciPy`, avec les labels des thèmes.

- Le dendrogramme des thèmes produit par cette suite de procédures est donné ci-dessous :

Figure 16 Dendrogramme des thèmes




- Le dendrogramme obtenu à partir des distances de Jaccard ne fait pas apparaître de coupure nette entre grands ensembles thématiques. La plupart des fusions interviennent à des distances élevées, ce qui indique que de nombreux thèmes partagent peu d'œuvres communes. Autrement dit, les thèmes ne se répartissent pas spontanément en blocs fortement séparés.

Ce résultat doit être interprété comme le signe d'une organisation thématique diffuse : certains rapprochements locaux existent, mais ils ne suffisent pas à produire une partition évidente et stable de l'ensemble des thèmes. Le dendrogramme fournit donc une première indication de proximité entre thèmes, mais ne permet pas à lui seul de justifier des méta-thèmes fortement constitués.

Analyse des distances de Jaccard


- La distribution des distances de Jaccard confirme l'impression donnée par le dendrogramme. Une majorité de couples de thèmes (70% environ) présente une distance égale à 1 ($d_j = 1$), ce qui signifie que les deux thèmes ne sont jamais présents ensemble dans une même œuvre du corpus. Les couples ayant une distance strictement inférieure à 1 constituent donc une minorité (30% environ) :

Figure 17 Distance de Jaccard entre thèmes (par rapport à 1)



- Une figure plus technique sur la distribution complète est fournie par souci d'exhaustivité :

Figure 18 Distance de Jaccard entre thèmes (graphiques divers)




- Le zoom sur les distances inférieures à 1 montre en outre que, même lorsque deux thèmes co-apparaissent au moins une fois, leur distance reste souvent élevée. Les rapprochements thématiques existent donc, mais ils sont généralement faibles ou localisés.
- Il faut rappeler que la distance de Jaccard mesure uniquement le recouvrement des présences. Les absences simultanées ne renforcent pas la proximité entre deux thèmes. Cette propriété est particulièrement adaptée à des données de présence / absence, car deux thèmes rares ne sont pas artificiellement rapprochés simplement parce qu'ils sont absents ensemble dans beaucoup d'œuvres.

Heatmap des distances de Jaccard

- Le graphique visualisant la coprésence des thèmes par les distances de Jaccard a été obtenu à l'aide de la fonction `heatmap` du package `seaborn` de Python :

Figure 19 Heatmap des distances de Jaccard entre thèmes



- La palette représente linéairement les distances de Jaccard entre 0.5 et 1.0 ; elle a été bornée entre 0.5 et 1 afin de mieux distinguer les distances élevées, majoritaires dans la matrice. Les distances inférieures à 0.5 sont représentées par la couleur minimale.

- La heatmap des distances de Jaccard, réordonnée selon le dendrogramme, permet de visualiser la structure globale des proximités thématiques. La prédominance des couleurs correspondant à des distances élevées confirme que la plupart des thèmes sont faiblement co-présents.

On observe quelques zones locales où les distances sont plus faibles, ce qui correspond à des familles de thèmes apparaissant plus souvent dans les mêmes œuvres. Cependant, ces zones restent limitées et ne forment pas de grands blocs homogènes le long de la diagonale. Le graphique confirme donc l'absence d'une structuration thématique très nette à l'échelle des 65 thèmes.

Il est préférable de ne pas parler ici d'indépendance statistique au sens strict : la heatmap montre surtout une faible co-présence globale, non une indépendance démontrée.

Technique MDS sur les thèmes

- La matrice des distances de Jaccard entre thèmes a été représentée dans un plan à l'aide de la technique MDS du package `scikit-learn` de Python.
- Dans le cas actuel, les distances de Jaccard sont des distances entre vecteurs binaires de longueur 173 (nombre d'œuvres) et chaque thème est donc un point dans un espace à 173 dimensions.
 - Toutefois on peut faire agir le MDS non pas directement sur l'espace de dimension 173 pour le réduire aux 2 dimensions d'un plan, mais sur une matrice de distances pré-calculées de taille 65×65 (la matrice des distances de Jaccard pré-calculées) en spécifiant l'option « `metric=precomputed` ».
 - Dans ce cas, le MDS agit comme technique de représentation de distances, plutôt que comme une simple technique de réduction de dimension au sens strict de l'ACP.
 - On a commencé par tester le résultat d'une variation du paramètre `n_init` ; les valeurs numériques obtenues sont résumées dans le tableau suivant :

Tableau 9 Choix du `n_init` (MDS) appliqué aux thèmes


<code>n_init</code>	stress	temps_secondes
1	312.964	0.063504
2	312.391	0.063693
4	312.391	0.064414
8	312.391	0.073278
16	310.011	0.154867
32	310.011	0.316170
64	310.011	0.590980
128	310.011	1.102006
256	309.755	2.194447
512	309.126	4.246609
1024	308.721	8.586287

- Le tableau comparant différentes valeurs de `n_init` montre que le stress diminue lorsque le nombre d'initialisations augmente, mais que les gains deviennent progressivement limités au regard du coût de calcul et de l'amélioration visuelle obtenue :

- À partir de `n_init` = 16, les gains supplémentaires de stress deviennent faibles au regard du coût de calcul et ne modifient pas de manière décisive la lecture graphique ; la technique MDS a donc été utilisée avec le nombre d'initialisations `n_init` = 16, en utilisant l'option `metric=precomputed` et l'initialisation `random`, signifiant qu'une initialisation aléatoire est employée.
- Le choix de `n_init` = 16 peut donc être présenté comme un compromis raisonnable : il améliore la stabilité de la solution par rapport à quelques initialisations seulement, tout en évitant d'augmenter inutilement le temps de calcul.

- Le résultat est donné par le graphique ci-dessous :

Figure 20 MDS des thèmes



- La projection MDS représente dans un plan les distances de Jaccard entre thèmes. Deux thèmes proches sur le graphique ont donc, dans la mesure où la projection en deux dimensions le permet, des profils de présence relativement proches dans le corpus.

Les thèmes les plus fréquents, tels que « Amour », « Femme », « Guerre », « Mort », « Argent » ou « Apprentissage », apparaissent visuellement comme des repères importants de la carte.

Leur taille et leur couleur signalent leur fréquence élevée, mais leur position dans le plan doit être interprétée avec prudence : les axes de la MDS n'ont pas de signification propre, contrairement aux axes d'une ACP.

La carte suggère quelques voisinages thématiques :

- des zones historiques et politiques autour de « Guerre », « Communisme », « Patrie », « Héros » ou encore « Révolution », « Socialisme », « Capitalisme », « Violence ».
- une zone sociale et idéologique autour de « Noblesse », « Traditions », « Intelligentsia », « Individu », « Servage »,
- une zone morale ou existentielle autour de « Mal », « Pouvoir », « Remords », « Hypocrisie », « Misère » ou « Humiliation ».

• Ces rapprochements restent toutefois exploratoires, d'autant que les axes de la MDS n'ont pas de signification propre ; ils indiquent des proximités de profils dans le corpus, mais ne doivent pas être interprétés comme des regroupements littéraires définitifs.

Co-occurrence des thèmes

• La matrice `matrix_themes` contient les données binaires de présence / absence de thèmes dans une œuvre, où les thèmes sont organisés en colonne.

En multipliant la transposée de cette matrice par elle-même on obtient une matrice de co-occurrence des thèmes, `matrix_co_occurrence`, de taille 65×65 , dont un extrait est donné ci-dessous par souci de contrôle :

Tableau 10 Extrait de la matrice de co-occurrence des thèmes

matrix_co_occurrence											
	Nature	Apprentissage	Servage	Noblesse	Traditions	Education	Campagne	Individu	Russie	Occident	...
Nature	17	4	2	3	4	0	1	2	0	0	...
Apprentissage	4	18	1	1	3	1	1	0	1	1	...
Servage	2	1	8	7	4	1	0	0	0	0	...
Noblesse	3	1	7	18	5	1	1	1	2	5	...
Traditions	4	3	4	5	17	2	2	0	1	1	...
...	...	...	...	...	...	...	...	...	...	...	...

• La matrice de co-occurrence mesure le nombre d'œuvres dans lesquelles deux thèmes apparaissent simultanément.

Contrairement à la distance de Jaccard, elle n'est pas normalisée : les thèmes les plus fréquents ont donc mécaniquement plus de chances de présenter des co-occurrences élevées.

Les co-occurrences brutes donnent une première indication des associations thématiques les plus fréquentes.

Elles sont toutefois complétées par l'analyse des distances de Jaccard, qui permet d'évaluer la proximité relative entre thèmes en tenant compte de leur fréquence d'apparition dans le corpus.

Cette approche transforme la matrice binaire œuvres $\times$ thèmes en une matrice relationnelle thèmes $\times$ thèmes, permettant d'étudier non plus les œuvres isolément, mais l'organisation globale des relations thématiques à l'intérieur du corpus.


Cette matrice contient :

- sur sa diagonale, le nombre de fois où le thème correspondant est apparu dans les œuvres du corpus (le maximum rencontré est 57, pour le thème « Amour »)
 - en-dehors de sa diagonale, le nombre de fois où le couple de thèmes correspondants est apparu dans les œuvres du corpus (le maximum rencontré est 27, pour le couple « Amour » et « Femme »)
- Le graphique visualisant le nombre de co-occurrences des thèmes a été obtenu à l'aide de la fonction heatmap du package seaborn de Python :

La heatmap fait apparaître quelques zones de co-présence plus marquée, mais la majorité des couples restent peu fréquents. Ce graphique doit donc être lu comme une carte des relations quantitatives entre thèmes, et non comme une mesure directe de similarité sémantique.

- Le graphique est présenté ci-dessous.

Figure 21 Heatmap de co-occurrence des thèmes



Représentation des thèmes en réseau

- Les thèmes ont été représentés en réseau en utilisant les valeurs de la matrice de co-occurrence, à l'aide du package `networkx` de Python.

Le réseau créé possède :

- des nœuds (les thèmes),
- des arêtes (les co-occurrences),
- des poids (le nombre des co-occurrences)

Le réseau présenté est un graphe pondéré et filtré de co-occurrence des thèmes. Chaque arête relie deux thèmes apparaissant conjointement dans les mêmes œuvres, et son poids correspond au nombre de co-occurrences observées entre ces deux thèmes. Les arêtes ont été colorisées en fonction de ce poids, afin de faire apparaître l'intensité relative des associations thématiques.

Cette approche est proche des méthodes utilisées en théorie des graphes et dans l'étude des réseaux complexes (social networks, réseaux biologiques, réseaux lexicaux, etc.).

- Afin de rendre la figure lisible, le graphe a été filtré en ne conservant que les arêtes dont le poids est supérieur ou égal à un certain seuil. Le réseau ne représente donc pas toutes les relations possibles entre thèmes, mais uniquement les co-occurrences les plus fréquentes. Les relations plus faibles sont volontairement exclues.

Une analyse de sensibilité a été effectuée sur le niveau du seuil, pour une valeur comprise entre 3 et 8, en calculant les éléments de la structure du réseau ; le tableau est présenté ci-après et montre que lorsque le seuil augmente, le réseau se simplifie fortement :

Tableau 11 Choix d'un seuil pour le réseau des thèmes

seuil	nombre de nœuds actifs	nombre d'arêtes	nombre de communautés	modularité
3	51	107	6	0.291
4	34	57	6	0.262
5	22	32	3	0.237
6	15	17	3	0.224
7	11	13	3	0.190
8	8	9	2	0.163

On appelle ici nœud actif un thème conservé dans le réseau après filtrage, c'est-à-dire un thème relié à au moins un autre thème par une arête de poids supérieur ou égal au seuil choisi.

- Une liste des communautés par seuil est présentée dans la partie **Annexe (A8)**. On constate que les communautés ne sont pas entièrement stables, mais que certains noyaux thématiques le sont.


- Par exemple, le groupe « Guerre », « Patrie » reste visible aux divers seuils, perdant ou gagnant certains thèmes selon le cas.
- De même, le couple « Noblesse », « Servage » reste visible, même si « servage » disparaît au seuil le plus élevé.
- Enfin, un ensemble regroupant « Amour », « Femme », « Bonheur », « Mort », « Argent » apparaît à partir du seuil 4 et reste visible aux seuils suivants. Au seuil 3, « Mort » et « Argent » sont regroupés ensemble, mais dans une communauté distincte de celle d'« Amour », « Femme » et « Bonheur ».

L'analyse de sensibilité montre que le choix du seuil influe sur la composition exacte des communautés. Les communautés obtenues doivent donc être interprétées comme une aide exploratoire à la lecture des proximités thématiques, et non comme une partition définitive des thèmes.

On a retenu le seuil 5 comme un compromis entre richesse du réseau et lisibilité graphique : il conserve suffisamment de relations pour permettre une interprétation littéraire, tout en éliminant les associations trop faibles.

- Le réseau obtenu pour ce seuil est présenté dans le graphique qui suit :

Figure 22 Réseau des thèmes



- Dans ce réseau, « Amour » et « Femme » occupent une position centrale dans le réseau des co-occurrences et apparaissent comme des thèmes fortement connectés.
 - Cette centralité suggère qu'ils jouent un rôle de points de passage entre plusieurs ensembles thématiques, un rôle de thèmes-pivots capables d'articuler entre eux des ensembles thématiques très variés tels que famille, morale, société, pouvoir, religion, nature ou révolution...
 - Leur forte connectivité peut être interprétée comme un indice de leur transversalité narrative dans le corpus étudié.
 - Leur forte transversalité dans le corpus doit toutefois être interprétée en tenant compte de leur fréquence élevée : un thème fréquent tend naturellement à être relié à davantage d'autres thèmes.
- Le réseau met également en évidence quelques ensembles cohérents, par exemple autour de « Guerre », « Patrie », « Communisme », « Héros » et « Révolution », ou autour de « Noblesse », « Servage » et « Traditions ». Ces regroupements sont intéressants car ils apparaissent cohérents dans le réseau des co-occurrences et qu'ils présentent également une certaine plausibilité littéraire.

Construction de communautés de thèmes

- Le package `networkx` permet d'établir une partition du graphe pondéré en communautés, en maximisant une quantité appelée « modularité », à l'aide d'un algorithme spécialement dédié :
`algorithms.community.greedy_modularity_communities` :

➤ Le détail de construction de la modularité est donné dans la partie **Annexe (A7)**.

La logique est qu'une « bonne » communauté est un groupe de nœuds qui possède beaucoup plus de connexions internes que ce qu'on observerait dans un réseau aléatoire comparable.

En d'autres termes, l'algorithme de modularité appliqué au graphe pondéré ne cherche pas les groupes les plus connectés, mais extrait des communautés de thèmes : il cherche les groupes plus densément connectés entre eux que ce que le hasard permettrait d'attendre.

- Par exemple, dans le graphe précédent (*seuil* = 5), les thèmes « Amour » et « Femme » sont très centraux et sont reliés à beaucoup d'autres thèmes, ce qui fait qu'on pourrait être tenté de les considérer automatiquement comme le cœur d'une communauté.

Mais la modularité raisonne autrement :

- Amour est relié à beaucoup de thèmes ;
- Femme est relié à beaucoup de thèmes ;
- donc une liaison Amour–Femme est déjà en partie attendue.

La question devient alors : « Leur liaison est-elle encore plus forte que ce que leurs degrés respectifs laisseraient prévoir ? »

- Il est important de préciser que ces communautés dépendent du graphe effectivement construit, donc notamment du seuil de co-occurrence choisi. Elles ne constituent pas une vérité absolue sur les thèmes, mais une partition possible du réseau filtré. Leur intérêt est de fournir une proposition de regroupement fondée sur la structure relationnelle des co-occurrences.
- Avec un seuil de 5, trois communautés de thèmes sont extraites parmi les 22 thèmes actifs du réseau ; les thèmes sans arête à ce seuil ne sont pas inclus dans cette partition.

Tableau 12 Communautés de thèmes extraites du réseau (*seuil*=5)

seuil = 5		
communauté_1	communauté_2	communauté_3
thèmes	thèmes	thèmes
Amour	Communisme	Noblesse
Argent	Guerre	Occident
Bonheur	Héros	Servage
Campagne	Patrie	Traditions
Dieu	Révolution	
Femme		
Intelligentsia		
Mal		
Mort		
Nature		
Pouvoir		
Rêve		
Solitude		

La partition obtenue peut être utilisée comme argument complémentaire pour discuter d'éventuels méta-thèmes, à condition de la confronter aux résultats du dendrogramme, de la MDS, de l'ACP et à l'interprétation littéraire.

La modularité obtenue pour un seuil égal à 5, $Q = 0.237$, indique une structuration communautaire positive mais limitée du réseau. Les trois communautés détectées ne doivent donc pas être interprétées comme des ensembles hermétiques, mais plutôt comme des pôles thématiques relativement cohérents, entre lesquels subsistent de nombreuses connexions.

ACP sur les thèmes

- On utilise la matrice des thèmes, `matrix_themes`, où les cellules contiennent 0 si le thème n'est pas répertorié dans l'œuvre et 1 si le thème est répertorié.


L'ACP est appliquée à la matrice transposée afin de considérer les thèmes comme des individus décrits par leur profil d'apparition dans les œuvres.

Les données ont été centrées par l'ACP, mais non réduites par `StandardScaler`, afin de conserver le poids descriptif des fréquences d'apparition des thèmes.

Cette analyse est utilisée comme représentation exploratoire complémentaire, en parallèle du dendrogramme, de la MDS et du graphe de co-occurrence.

- Les deux premiers axes recueillent environ 20% de la variance totale :

Figure 23 ACP des thèmes du corpus (variance des composantes)




Le graphique de variance expliquée montre que les deux premiers axes de l'ACP ne résument qu'environ un cinquième de l'information totale. La variance est donc distribuée sur un grand nombre de composantes, ce qui confirme que la structure des thèmes est diffuse et difficile à réduire à deux dimensions.

Le premier plan factoriel reste néanmoins utile comme outil exploratoire. Il permet d'identifier les thèmes dont les profils d'apparition sont les plus atypiques, mais il ne doit pas être interprété comme une représentation exhaustive de l'organisation thématique du corpus.

- Le graphique de l'ACP sur les deux premiers axes est représenté ci-dessous :

Figure 24 ACP des thèmes PC1 × PC2



• Les trois thèmes « Amour », « Femme », « Guerre », apparaissent largement séparés des autres. La concentration des autres thèmes près de l'origine indique qu'ils sont peu différenciés par les deux premiers axes ; leur interprétation individuelle reste donc limitée à partir de ce seul plan factoriel.

Toutefois, les trois thèmes fortement excentrés dans le plan factoriel ne doivent donc pas être interprétés immédiatement comme des thèmes « séparés » au sens littéraire. Leur éloignement indique d'abord qu'ils possèdent des profils d'apparition atypiques par rapport aux autres thèmes du corpus.

Cette singularité peut provenir :

- soit d'une fréquence très élevée, les thèmes pesant statistiquement parce qu'ils apparaissent dans beaucoup d'œuvres,
- soit d'une concentration dans un sous-ensemble particulier d'œuvres, avec des thèmes présents dans un petit ensemble d'œuvres qui ne ressemble pas au profil moyen des autres œuvres,
- soit d'associations thématiques spécifiques, thèmes associés à une famille d'œuvres très caractéristique, œuvres d'un certain auteur, d'une certaine période, ou d'un certain type littéraire.

Il est donc nécessaire de compléter la lecture du graphique par l'examen de leur fréquence et de leurs principales co-occurrences. Les thèmes les plus excentrés sont indiqué ci-dessous :

Tableau 13 Identification des thèmes les plus excentrés

Thèmes	PC1	PC2	Distance à l'origine	Fréquence
<i>Amour</i>	6.266309	1.202615	6.380667	57
<i>Femme</i>	4.836847	-0.902922	4.920403	44
<i>Guerre</i>	0.239033	4.201218	4.208012	25
<i>Patrie</i>	-0.604322	2.019183	2.107678	10
<i>Noblesse</i>	0.895187	-1.196920	1.494650	18
<i>Communisme</i>	-0.624974	1.330452	1.469930	8
<i>Argent</i>	0.681573	-1.197091	1.377523	21
<i>Mort</i>	1.346287	-0.288067	1.376761	22
<i>Traditions</i>	0.321335	-1.223953	1.265432	17

- Identification des co-occurrences les plus importantes pour les trois thèmes les plus excentrés :

Tableau 14 Identification des co-occurrences les plus importantes

Amour		Femme		Guerre	
thème associé	co-occurrence	thème associé	co-occurrence	thème associé	co-occurrence
<i>Femme</i>	27	<i>Amour</i>	27	<i>Patrie</i>	10
<i>Mort</i>	11	<i>Mort</i>	9	<i>Amour</i>	8
<i>Bonheur</i>	9	<i>Noblesse</i>	8	<i>Communisme</i>	6
<i>Guerre</i>	8	<i>Argent</i>	8	<i>Héros</i>	5
<i>Noblesse</i>	8	<i>Traditions</i>	7	<i>Révolution</i>	5
<i>Occident</i>	7	<i>Révolution</i>	6	<i>Responsabilité</i>	4
<i>Argent</i>	7	<i>Intelligentsia</i>	6	<i>Femme</i>	4
<i>Dieu</i>	6	<i>Bonheur</i>	5	<i>Art</i>	3
<i>Nature</i>	5	<i>Dieu</i>	5	<i>Société</i>	3

- En conclusion, l'ACP réalisée sur la matrice thèmes × œuvres fait apparaître trois thèmes nettement excentrés : « Amour », « Femme » et « Guerre ». Ces thèmes ne doivent pas être compris comme des anomalies, mais comme des points fortement structurants du premier plan factoriel.

- Les deux premiers, très positifs sur le premier axe, définissent un pôle romanesque et relationnel, centré sur les relations amoureuses, les figures féminines et les conflits affectifs. Leur proximité est confirmée par leur forte co-occurrence : « Amour » et « Femme » apparaissent ensemble dans 27 œuvres.
- Le thème « Guerre », en revanche, se distingue principalement sur le second axe. Ses principales co-occurrences avec « Patrie », « Communisme », « Héros » et « Révolution » suggèrent un pôle historique, politique et collectif.

Ainsi, le premier plan factoriel ne met pas seulement en évidence des thèmes isolés ; il suggère deux directions interprétables : une direction relationnelle et romanesque autour de « Amour » et « Femme » et une direction historique, guerrière et idéologique autour de « Guerre ».


Cette interprétation doit toutefois rester prudente, car les deux premiers axes n'expliquent qu'environ 19 % de la variance totale, et l'ACP sans standardisation donne un poids important aux thèmes les plus fréquents.

ACP des thèmes – axes supplémentaires

L'examen des axes 3 et 4 ne modifie pas l'interprétation principale fournie par le premier plan factoriel. Ces deux axes, qui expliquent ensemble moins de 10 % de la variance, font apparaître quelques déplacements secondaires — notamment autour de thèmes tels que « Société », « Argent », « Révolution », « Noblesse », « Nature » ou « Traditions » — mais ils ne révèlent pas de structuration thématique aussi nette que celle observée sur les axes 1 et 2.

On peut donc considérer que l'essentiel de l'information interprétable de l'ACP se concentre dans le premier plan, tandis que les axes suivants apportent plutôt des nuances locales.

Figure 25 ACP des thèmes sur les axes 3 et 4



Ce graphique confirme que les axes 3 et 4 apportent des nuances locales mais ne modifient pas l'interprétation principale fondée sur les axes 1 et 2.

Évolution des thèmes par périodes

- Pour compléter la chronologie essentiellement descriptive des thèmes, un travail a été effectué sur la façon dont les thèmes ont évolué dans les œuvres, selon leur date de composition classée par périodes historiques.

➤ Pour ce faire, un graphique en double heatmap thèmes×périodes a été réalisé, qui présente les profils thématiques normalisés des œuvres selon deux découpages chronologiques :

- une périodisation historique fine, à gauche,
- et une opposition synthétique avant / après 1917, à droite.

La couleur indique, pour chaque période, le pourcentage d'œuvres dans lesquelles un thème est présent. Le graphique ne mesure donc pas le nombre absolu d'occurrences d'un thème, mais son poids relatif dans les œuvres appartenant à une période donnée.

- La première observation est la permanence de certains grands thèmes :
 - « Amour », « Femme », « Nature », « Mort », « Société », ou encore « Souffrance » apparaissent à plusieurs moments de la chronologie. Ils constituent des thèmes transversaux de la base, qui ne sont pas propres à une seule période.
 - Toutefois, leur intensité varie fortement selon les moments : par exemple, « Amour » et « Femme » sont particulièrement visibles dans les périodes du *XIX^e* siècle, tandis que « Société » devient nettement plus marquée dans les périodes postérieures.
- La périodisation historique fait apparaître des profils assez différenciés :
 - Les périodes anciennes et le *XIX^e* siècle sont caractérisées par des thèmes liés à l'ordre social traditionnel ou à l'univers littéraire classique : « Noblesse », « Servage », « Religion », « Nature », « Fonctionnaires », « Femme », « Amour », « Occident ».
 - La période [1850 – 1905[semble concentrer plusieurs thèmes centraux du grand roman russe : « Amour », « Femme », « Mort », « Misère », « Nature », « Noblesse », « Occident », mais aussi des dimensions sociales et morales.
 - La période [1905 – 1917[, plus courte, fait davantage apparaître des thèmes de crise : « Misère », « Mort », « Humanisme », « Socialisme », « Révolution », ce qui correspond assez bien à l'idée d'une période de tension pré-révolutionnaire.
- Après 1917, le profil thématique se modifie nettement.
 - Les périodes [1917 – 1953[et [1953 – 1991[font ressortir des thèmes plus directement liés à l'histoire politique et sociale du *XX^e* siècle : « Guerre », « Communisme », « Patrie », « Révolution », « Société », « Camps », « Responsabilité », « Travail », « Souffrance ».
 - On observe donc un déplacement partiel du centre thématique : les thèmes sociaux, historiques et collectifs prennent davantage de poids, alors que certains thèmes associés au monde ancien — « Noblesse », « Servage », « Fonctionnaires », « Occident » — se concentrent plutôt jusqu'en 1917 inclus.

- La heatmap avant / après 1917 confirme cette opposition générale, mais de manière plus simplifiée :
 - Elle montre clairement que certains thèmes sont plus caractéristiques de l'avant-1917, notamment « Noblesse », « Mort », « Fonctionnaires », « Dieu », « Orgueil », « Fantastique », ou « Femme ».
 - À l'inverse, l'après-1917 met davantage en avant « Guerre », « Communisme », « Patrie », « Révolution », « Société », « Responsabilité », et certains thèmes liés à l'expérience collective ou historique.
 - Cette seconde heatmap fonctionne donc comme une synthèse visuelle : elle suggère que 1917 constitue bien une coupure thématique pertinente dans le corpus étudié, même si cette rupture ne fait pas disparaître les continuités.

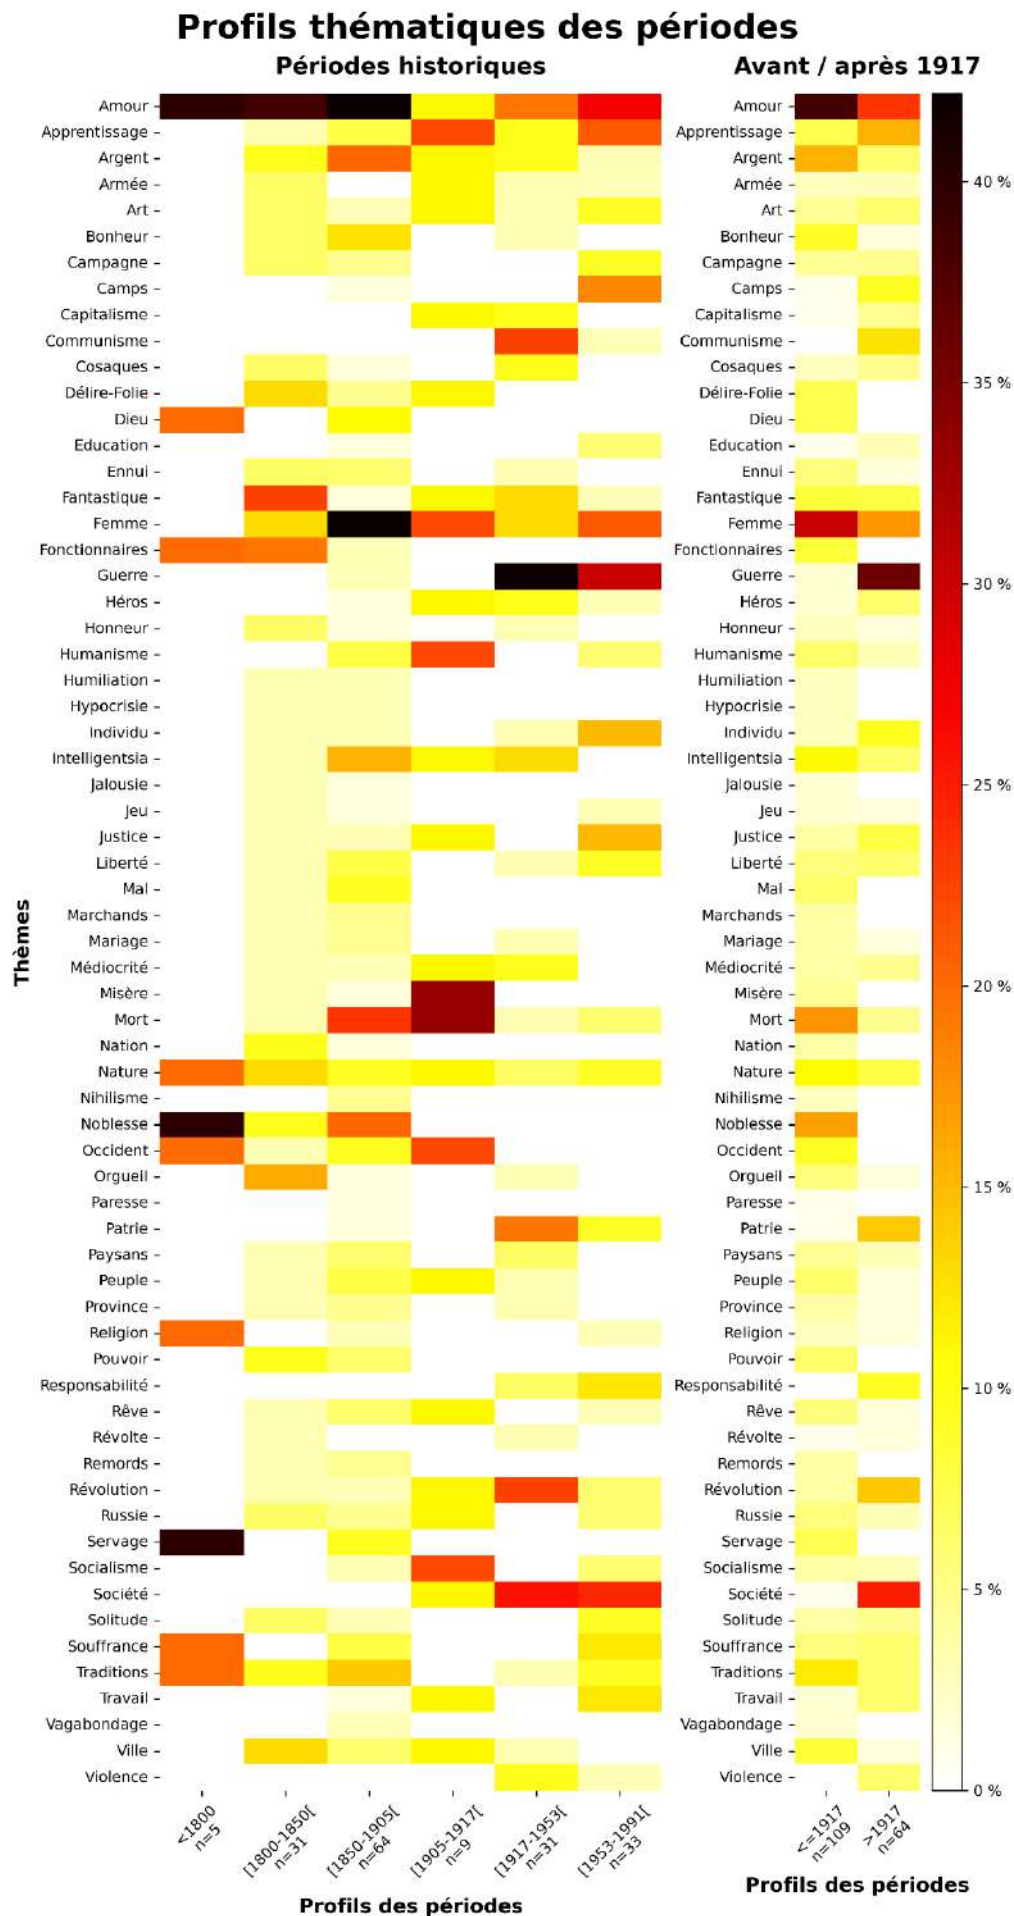
Il faut toutefois rester prudent dans l'interprétation. Comme les profils sont normalisés par période, une couleur forte ne signifie pas nécessairement qu'un thème est fréquent dans toute la base ; elle signifie qu'il est relativement important à l'intérieur de la période considérée.

Les périodes courtes ou faiblement représentées peuvent donc produire des contrastes visuels marqués. Le graphique doit être lu comme une carte des dominantes thématiques, non comme une mesure brute de fréquence.

- Le graphique commenté ci-dessus est présenté sur la page suivante.

On notera que la période ≥ 1991 n'apparaît pas dans la heatmap, ce qui n'est pas le résultat d'un oubli, mais vient du fait que le corpus issu du dictionnaire ne contient pas d'œuvre postérieure à 1970.

Figure 26 Heatmap des thèmes par périodes historiques



Les thèmes et la rupture de 1917

- Un graphique simplifié a été réalisé, sous forme d'un barplot horizontal comparatif divergent, reprenant les thèmes qui présentent les plus forts écarts de fréquence :
 - entre les œuvres composées jusqu'en 1917 inclus,
 - et celles composées après 1917.

Sur ce graphique, au lieu de représenter les deux fréquences séparément, on calcule l'écart :

$$\text{écart} = \text{fréquence après 1917} - \text{fréquence jusqu'en 1917 inclus}$$

puis on représente les thèmes qui ont les écarts les plus forts ; chaque barre représente donc l'écart entre la fréquence d'un thème après 1917 et sa fréquence jusqu'en 1917 inclus.


La fréquence correspond à la proportion d'œuvres d'une période dans lesquelles le thème est présent :

- un écart positif signifie donc que le thème est plus fréquent dans les œuvres composées après 1917
 - un écart négatif signifie qu'il est plus fréquent dans les œuvres composées jusqu'en 1917 inclus.
- À noter que les valeurs sont exprimées en points de pourcentage : par exemple, un écart de +20 indique que le thème apparaît dans une proportion d'œuvres supérieure de 20 points après 1917 par rapport à la période jusqu'en 1917 inclus.

On précise que ces écarts ne sont pas des tests statistiques de significativité : ils indiquent des surreprésentations descriptives et ne constituent pas, à eux seuls, un test statistique de différence entre périodes.

- Le graphique est représenté sur la page suivante :

Figure 27 Barplot des thèmes par rapport à 1917



Recherche de clusters


- On a appliqué sur les thèmes une méthode de clustering hiérarchique ascendante.

Principe :

- chaque observation est initialement considérée comme un cluster distinct,
- à chaque étape, les deux clusters les plus proches sont fusionnés,
- la distance entre clusters est définie soit par la moyenne des distances entre leurs éléments avec la méthode `linkage = "average"`, soit par la plus grande de ces distances avec la méthode `linkage = "complete"`,
- les distances entre observations sont fournies sous forme d'une matrice pré-calculée, par l'option `metric = "precomputed"` ; ici, la matrice de distances utilisée est la matrice des distance de Jaccard entre les thèmes,
- le processus continue jusqu'à obtenir le nombre de clusters souhaité.

- Pour chaque méthode de linkage, un score silhouette a été calculé, puis un indice de Rand ajusté (ARI) permettant de comparer les deux méthodes. Les graphiques résultants sont donnés ci-dessous :

Figure 28 Recherche d'un clustering des thèmes



- Le graphique des scores montre une augmentation quasi monotone, avec valeurs très faibles quelle que soit la méthode utilisée.

À titre de repère pratique, des valeurs nettement supérieures, par exemple au-delà de 0.25, indiqueraient une structure plus visible.

Ce n'est pas le cas ici, avec des scores restant très faibles : il n'y a probablement pas de structure de clusters très nette dans les données et le maximum observé (~0.07) reste trop faible pour indiquer une séparation exploitable des thèmes.

L'indice de Rand compare les deux types de clustering pour un même nombre de clusters : il mesure la stabilité entre les méthodes, et non pas la qualité intrinsèque des méthodes. Typiquement, la signification de l'ARI est donnée par :

- ≈ 1 ... partitions presque identiques
- $\approx 0.7-0.9$... très proches
- $\approx 0.4-0.6$... différences notables
- < 0.3 ... partitions instables

Toutefois, l'interprétation d'un ARI dépend du contexte et du nombre de groupes :

L'indice de Rand ajusté est proche de 1 lorsque les deux partitions sont très semblables, proche de 0 lorsque leur concordance n'est guère supérieure à celle attendue par hasard, et peut devenir négatif lorsque leur accord est inférieur à cette référence. Dans le cas présent, les valeurs restent généralement faibles ; leur augmentation pour les nombres de clusters les plus élevés ne compense pas les très faibles scores de silhouette.

- Il est clair ici que les clusterings n'ont pas de stabilité et que la procédure ne permet pas de regrouper les thèmes en des « méta-thèmes » clairement identifiables.

Analyse des correspondances entre auteurs et thèmes

Construction de la matrice de travail

• Dans le but d'examiner les proximités entre les auteurs et les thèmes, une analyse des correspondances (AC) a été menée sur ces deux variables qualitatives, selon la procédure détaillée ci-dessous.

La matrice générale `matrix_all_extended` a d'abord été simplifiée en une matrice contenant uniquement les colonnes des œuvres (Works), des auteurs (Author) et les colonnes des thèmes (en 0/1), puis, sur cette matrice simplifiée :

- une sélection a été faite sur les œuvres à analyser, car il a été vu qu'une œuvre contient en moyenne 3.61 thèmes : n'ont alors été conservées que les œuvres les plus densément indexées du corpus, c'est-à-dire celles auxquelles au moins quatre thèmes sont associés, ce qui conserve 76 œuvres (se reporter à la figure 3), conduisant à créer une liste *W* d'œuvres.
- indépendamment de la sélection précédente, une sélection a été faite sur les thèmes à analyser, car il a été vu qu'un thème apparaît en moyenne dans 9.60 œuvres : n'ont alors été conservés que les thèmes apparaissant dans au moins 10 œuvres, ce qui concerne 19 thèmes (se reporter à la Figure 4), conduisant à créer une liste *T* de thèmes.
- finalement, les listes *W* d'œuvres (en lignes) et *T* de thèmes (en colonnes) ont été combinées pour créer une matrice réduite contenant les œuvres et les thèmes considérés comme les plus densément indexées dans le *Dictionnaire* (ainsi que les auteurs correspondant à ces œuvres).
- concrètement, le critère « œuvres contenant au moins 4 thèmes » a été calculé avant la réduction des colonnes, donc sur l'ensemble initial des thèmes présents dans la matrice simplifiée, ce qui constitue le choix le plus logique.
- les seuils 4 et 10 ont été retenus comme critères opérationnels de réduction et de lisibilité car ils sont proches des moyennes observées ; mais ils ne correspondent pas à des seuils de significativité statistique et le filtrage reste conventionnel.

Sur cette matrice « œuvres-auteurs × thèmes », on a calculé un profil thématique par auteur :

- en regroupant toutes les lignes de thèmes qui appartiennent à un même auteur,
- en appliquant pour chaque thème une somme en colonne à l'intérieur de chaque groupe de lignes appartenant à un même auteur.

Le résultat est alors une matrice auteurs × thèmes où chaque case contient :

$$n_{ij} = \text{nombre d'attributions du thème } j \text{ aux œuvres de l'auteur } i.$$

L'unité de comptage de l'AC est donc l'occurrence auteur-œuvre-thème, et non l'œuvre prise isolément.


Cette matrice finale de profil thématique, `matrix_reduced_profile`, compte finalement 40 lignes d'auteurs et 19 colonnes de thèmes. Elle est donnée dans sa version complète dans la partie **Annexe (A9)**.

• L'analyse des correspondances a été effectuée sur `matrix_reduced_profile`, constituée par conséquent d'une table de contingence auteurs × thèmes, où les effectifs correspondent au nombre d'œuvres associées à chaque thème. Cette réduction de la matrice initiale vise à améliorer la lisibilité de la représentation graphique en se concentrant sur les associations les plus fréquentes du corpus.

Graphique AC

- L'analyse a été effectuée avec le package `prince` et l'option `engine="sklearn"` ; le graphique résultant est présenté ci-dessous :

Figure 29 Analyse des correspondances Auteurs-Thèmes



- Le graphique représente les auteurs et les thèmes sur le premier plan factoriel de l'analyse des correspondances, c'est-à-dire sur les axes 1 et 2. Dans cette analyse, l'axe 1 explique 16.37 % de l'inertie et l'axe 2 en explique 12.54 %. Le plan 1 – 2 représente donc au total 28.91 % de l'inertie. Cette proportion permet une première lecture partielle de la structure, à condition de la limiter aux points suffisamment bien représentés, mais elle rappelle aussi que le plan 1 – 2 ne résume qu'une partie de l'information contenue dans la matrice.

Contributions et carrés du cosinus

- Pour éviter une interprétation trop rapide du graphique, une analyse complémentaire a donc été effectuée. L'analyse des correspondances a été recalculée avec tous les axes factoriels possibles, et non plus seulement avec les deux premiers axes.

Cette étape permet d'évaluer la place du plan 1 – 2 par rapport à l'ensemble de l'espace factoriel. En effet, un auteur ou un thème peut être visible sur le graphique sans être correctement représenté par ce plan : une partie importante de son information peut se trouver sur d'autres axes.

Deux indicateurs ont été utilisés pour contrôler l'interprétation du graphique : les contributions et les $\cos^2$.

➤ Ces deux notions sont détaillées de façon plus approfondie dans la partie **Annexe (A10)**.

- Les contributions indiquent dans quelle mesure un point participe à la construction d'un axe ou d'un plan factoriel. Une forte contribution signifie qu'un auteur ou un thème joue un rôle important dans la définition de la structure visible sur le graphique. À l'inverse, un point faiblement contributeur peut apparaître sur le graphique, mais il intervient peu dans la formation des axes représentés.

Pour le plan 1 – 2, la contribution d'un point a été calculée en tenant compte de sa contribution aux deux axes, pondérée par l'importance respective de ces axes. Autrement dit, la contribution au plan 1 – 2 n'est pas une simple addition mécanique : elle tient compte du fait que l'axe 1 et l'axe 2 n'ont pas exactement le même poids dans l'inertie totale.

Plus précisément, pour un point i , la contribution au plan 1 – 2 est calculée comme une moyenne des contributions aux deux axes, pondérée par leurs inerties respectives :

$$Ctr_{i,(1,2)} = \frac{\lambda_1 Ctr_{i,1} + \lambda_2 Ctr_{i,2}}{\lambda_1 + \lambda_2}$$

où λ_1 et λ_2 désignent les valeurs propres associées aux deux premiers axes. Cette pondération donne davantage de poids à l'axe qui représente la plus grande part de l'inertie du tableau.

Un seuil de contribution moyenne a ensuite été utilisé. Comme il y a 40 auteurs dans la matrice réduite, la contribution moyenne attendue d'un auteur est de :

$$100 / 40 = 2.5 \%$$

Comme il y a 19 thèmes, la contribution moyenne attendue d'un thème est de :

$$100 / 19 = 5.26 \%$$

Ces deux valeurs ne sont donc pas des seuils arbitraires : elles correspondent à la contribution qu'aurait chaque point si tous les auteurs, ou tous les thèmes, contribueraient également au plan factoriel. Un auteur est ainsi considéré comme fortement contributeur s'il contribue au plan 1 – 2 au moins à hauteur de 2.5 %. Un thème est considéré comme fortement contributeur s'il contribue au plan 1 – 2 au moins à hauteur de 5.26 %.

- Le second indicateur utilisé est le $\cos^2$, ou carré du cosinus. Il mesure la qualité de représentation d'un point sur un axe ou sur un plan. Un $\cos^2$ élevé signifie que la position du point sur le graphique est fiable : le plan 1 – 2 rend bien compte de sa position dans l'espace factoriel. Un $\cos^2$ faible signifie au contraire que le point est mal projeté sur ce plan : sa position apparente doit alors être interprétée avec prudence.

Pour le plan 1 – 2, le $\cos^2$ retenu correspond à la somme du $\cos^2$ sur l'axe 1 et du $\cos^2$ sur l'axe 2. Il indique donc la part de l'information du point représentée par le premier plan factoriel. Dans cette analyse, un seuil pratique de 25 % a été retenu : cela signifie que l'on ne commente prioritairement que les points dont au moins un quart de l'information factorielle est représenté sur le plan 1 – 2.

Ce seuil de 25 % ne se déduit pas des seuils de contribution moyenne de 2.5 % et 5.26 %. Il s'agit d'un critère indépendant. Les contributions répondent à la question : ce point participe-t-il fortement à la construction du plan ? Les $\cos^2$ répondent à une autre question : ce point est-il correctement représenté sur le plan ? Les deux critères sont donc complémentaires.

Points retenus pour l'interprétation

- Les points retenus pour l'interprétation sont ceux qui satisfont simultanément deux conditions :
 - contribution au plan 1 – 2 $\geq$ contribution moyenne attendue
 - $\cos^2$ sur le plan 1 – 2 $\geq 25 \%$

Cette double sélection permet d'éviter deux erreurs. La première serait de commenter des points bien représentés mais peu importants pour la construction du plan. La seconde serait de commenter des points très contributeurs mais mal projetés sur le graphique. L'interprétation porte donc prioritairement sur les auteurs et les thèmes qui sont à la fois structurants pour le plan factoriel et suffisamment bien représentés par ce plan.

Cette démarche ne signifie pas que les autres points sont sans intérêt. Elle signifie seulement que leur position sur le graphique doit être interprétée avec davantage de prudence. Le graphique d'analyse des correspondances reste une représentation synthétique : il sert à dégager les principales oppositions et associations entre profils thématiques, mais il ne doit pas être lu comme une carte exhaustive de toutes les relations entre auteurs et thèmes.

- Les points retenus pour l'interprétation ont été désignés sous les vocables de :
 - « auteurs interprétables »
 - « thèmes interprétables »

Ils sont présentés dans les tableaux ci-dessous :

Tableau 15 Auteurs interprétables en AC

Auteur	Contribution axe 1	Contribution axe 2	Contribution plan 1-2	Cos² axe 1	Cos² axe 2	Cos² plan 1-2
FADEÏEV	20.87 %	1.47 %	12.46 %	85.65%	4.64%	90.29%
POLEVOÏ	20.87 %	1.47 %	12.46 %	85.65%	4.64%	90.29%
FEDINE	13.34 %	0.97 %	7.98 %	80.86%	4.49%	85.34%
BERGHOLTS	17.00 %	0.38 %	9.79 %	80.92%	1.38%	82.30%
GUINZBOURG	0.09 %	12.65 %	5.54 %	0.63%	68.39%	69.02%
SOLJENITSYNE	1.56 %	31.71 %	14.64 %	4.07%	63.10%	67.17%
TOURGUENIEV	2.72 %	3.12 %	2.89 %	22.53%	19.83%	42.35%
GORKI	0.05 %	9.90 %	4.32 %	0.21%	34.09%	34.31%

Tableau 16 Thèmes interprétables en AC


Thème	Contribution axe 1	Contribution axe 2	Contribution plan 1-2	Cos² axe 1	Cos² axe 2	Cos² plan 1-2
Guerre	37.20 %	2.32 %	22.07 %	80.98%	3.86%	84.84%
Patrie	45.30 %	2.25 %	26.63 %	77.19%	2.93%	80.12%
Société	2.53 %	32.33 %	15.46 %	5.43%	53.11%	58.53%
Souffrance	0.09 %	29.84 %	12.99 %	0.21%	53.36%	53.57%

Graphique complémentaire

- Afin de faciliter la lecture du plan factoriel, un second graphique est proposé en mettant en évidence les auteurs et les thèmes retenus pour l'interprétation, les autres points étant conservés en gris afin de restituer le contexte général du plan factoriel.

Il est représenté ci-dessous.

Figure 30 Analyse des correspondances Auteurs-Thèmes (points retenus)



- Le graphique reprend le même plan factoriel que le graphique précédent, c'est-à-dire le plan formé par les axes 1 et 2 de l'analyse des correspondances. Les coordonnées des points n'ont pas été recalculées : ce sont les mêmes coordonnées factorielles que dans le graphique complet. En revanche, seuls ont été mis en évidence les auteurs et les thèmes satisfaisant simultanément les deux critères définis plus haut : une contribution au plan 1 – 2 supérieure ou égale à la contribution moyenne attendue, et un $\cos^2$ sur le plan 1 – 2 supérieur ou égal à 25 %. Dans le cas présent, cette sélection retient huit auteurs —FADEÏEV, POLEVOÏ, FEDINE, BERGHOLTS, GUINZBOURG, SOLJENITSYNE, TOURGUENIEV, GORKI— et quatre thèmes —« Guerre », « Patrie », « Société » et « Souffrance ».

Ce second graphique ne remplace donc pas le graphique complet. Il en propose une lecture resserrée, limitée aux points les plus utiles pour l'interprétation du plan factoriel. Son objectif est de rendre plus lisibles les principales oppositions et proximités mises en évidence par l'analyse, en évitant de commenter des points faiblement contributeurs ou mal représentés.

Le plan factoriel ainsi simplifié fait apparaître une structure plus lisible que le graphique complet.

- L'axe 1 est principalement structuré par son pôle positif, occupé par les thèmes « Patrie » et « Guerre ». Ces deux thèmes sont fortement contributeurs au premier axe et sont également très bien représentés sur le plan 1 – 2 :

- le thème « Patrie » contribue à 26.63 % au plan et présente un $\cos^2$ de 80.12 %,
- le thème « Guerre » contribue à 22.07 % au plan et présente un $\cos^2$ de 84.84 %.

Ils constituent donc les deux thèmes les plus déterminants pour l'interprétation de l'axe horizontal.

Dans cette partie droite du graphique se trouvent notamment FADÉÏEV, POLEVOÏ, FEDINE et BERGHOLTS :

- FADÉÏEV et POLEVOÏ occupent une position presque identique, très à droite du plan factoriel, dans la même direction générale que le pôle défini par le thème « Patrie ». Leur position est fortement fiable sur le plan 1 – 2, avec un $\cos^2$ de 90.29 %, et leur contribution au plan est élevée, avec 12.46 % chacun. Ils apparaissent donc comme des auteurs très caractéristiques du pôle patriotique mis en évidence par l'analyse.
- FEDINE, également situé du côté positif de l'axe 1, se projette davantage du côté du pôle défini par « Guerre » que de celui défini par « Patrie » ; il participe donc lui aussi à ce pôle, mais selon une orientation légèrement différente.
- Enfin, la distance entre BERGHOLTS et ces deux points-thèmes n'a pas d'interprétation directe suffisamment sûre.

- L'axe 2 est principalement structuré par son pôle positif, où se trouvent les thèmes « Société » et « Souffrance ». Ces deux thèmes contribuent fortement au plan 1 – 2 et sont correctement représentés :

- le thème « Société » contribue à 15.46 % au plan et possède un $\cos^2$ de 58.53 %,
- le thème « Souffrance » contribue à 12.99 % au plan et possède un $\cos^2$ de 53.57 %.

L'axe vertical semble donc faire apparaître un pôle plus social et existentiel, marqué par les représentations de la société, de la contrainte, de l'épreuve ou de la souffrance.

Dans cette zone supérieure du graphique, SOLJENITSYNE et GUINZBOURG occupent une position particulièrement nette :

- SOLJENITSYNE est assez bon contributeur au plan, avec une contribution de 14.64 %, et il est bien représenté par le plan 1 – 2, avec un $\cos^2$ de 67.17 %. Sa position dans la même région générale du plan que « Société » et « Souffrance » est compatible avec un profil associé à ces dimensions.
- GUINZBOURG se situe encore plus près du thème « Souffrance », avec un $\cos^2$ de 69.02 %. Sa position confirme donc l'importance de ce pôle dans l'organisation du plan factoriel.
- GORKI se situe également dans la partie supérieure du plan, mais moins haut que SOLJENITSYNE et GUINZBOURG. Il participe donc au même versant général de l'axe 2, sans être aussi directement associé au pôle « Souffrance » / « Société ». Sa contribution au plan reste néanmoins suffisante pour qu'il soit retenu dans l'interprétation.

- BERGHOLTS occupe une position plus isolée, dans la partie droite et légèrement supérieure du graphique. Sa forte coordonnée positive sur l'axe 1 la rattache au versant droit du plan, mais sa position n'est pas aussi directement lisible que celle de FADEÏEV, POLEVOÏ ou FEDINE. Elle doit donc être interprétée avec davantage de prudence : BERGHOLTS contribue nettement au plan factoriel, mais sa proximité avec les quatre thèmes retenus est moins immédiatement explicite.
- Enfin, TOURGUENIEV est le seul auteur interprétable situé du côté négatif de l'axe 1 et du côté négatif de l'axe 2. Sa position l'oppose globalement aux deux pôles principaux visibles sur le graphique : d'une part le pôle « Patrie » / « Guerre », d'autre part le pôle « Société » / « Souffrance ». Toutefois, comme aucun thème interprétable ne se trouve dans la même zone que lui, il serait imprudent de lui associer directement un thème particulier à partir de ce seul graphique. Sa position indique surtout un profil distinct des auteurs les plus fortement associés aux pôles dominants du plan.

Au total, le graphique simplifié met donc en évidence deux pôles principaux. Le premier, situé à droite du plan, est organisé autour des thèmes « Patrie » et « Guerre », avec une association particulièrement nette à FADEÏEV, POLEVOÏ et FEDINE. Le second, situé dans la partie supérieure du plan, est organisé autour des thèmes « Société » et « Souffrance », avec une association forte à SOLJENITSYNE et GUINZBOURG. L'interprétation du plan 1 – 2 doit donc principalement s'appuyer sur cette double structuration, tout en gardant à l'esprit que le plan factoriel ne représente qu'une partie de l'inertie totale de l'analyse.

Conclusion de cette étude

Au terme de cette analyse, il convient de souligner un résultat qui, à première vue, peut sembler négatif, mais qui constitue en réalité l'un des enseignements les plus intéressants de ce travail.

Les différentes méthodes utilisées pour explorer la structure thématique du corpus — analyse en composantes principales, classification hiérarchique, dendrogrammes, représentation par MDS, analyse de réseau et scores de silhouette — n'ont pas permis de faire apparaître des ensembles thématiques suffisamment nets, stables et interprétables pour justifier la construction de « méta-thèmes ». L'analyse des correspondances, qui n'est pas une méthode de clustering, a complété cette exploration en faisant apparaître des directions locales, sans produire de partition globale stable.

Des pôles locaux apparaissent bien — autour de l'amour, de la guerre, de la patrie, de la noblesse ou du servage — mais ils ne suffisent pas à construire une typologie globale stable des thèmes.

L'analyse des correspondances menée sur la matrice réduite complète ce constat : le premier plan factoriel fait apparaître deux directions locales, structurées respectivement par les thèmes « Patrie »—« Guerre » et « Société »—« Souffrance », auxquelles se rattachent certains profils d'auteurs. Ces directions ne constituent cependant ni une partition des thèmes ni une typologie globale stable ; elles ne modifient donc pas la conclusion relative à l'absence de méta-thèmes clairement constitués.

Cette absence de regroupements clairement attestés ne doit pas être comprise comme un échec de l'analyse. Elle indique plutôt que les thèmes retenus ne se distribuent pas selon quelques grands blocs homogènes qui s'imposeraient naturellement. Les proximités existent, bien sûr, mais elles restent partielles, mobiles, parfois locales, et ne dessinent pas une architecture d'ensemble assez forte pour être présentée comme une structure profonde du corpus.

Dans ces conditions, toute tentative de réduction des thèmes à quelques familles générales aurait risqué de produire une construction artificielle, davantage imposée par l'interprétation que réellement soutenue par les données.

Ce constat invite donc à une certaine prudence. Il aurait été possible de fabriquer des catégories plus larges, de regrouper certains thèmes par affinité intuitive ou par commodité de présentation. Mais une telle opération n'aurait pas pu être documentée de manière suffisamment rigoureuse. Elle aurait donné une impression de clarté au prix d'une simplification excessive. Or l'un des objectifs de cette étude était précisément de laisser apparaître ce que les données permettaient de montrer, sans forcer leur organisation ni leur attribuer une cohérence qu'elles ne manifestaient pas clairement.

La conclusion qui s'impose est donc plus positive qu'il n'y paraît.

La littérature russe représentée dans ce corpus apparaît comme un espace thématique riche, varié, traversé par de multiples lignes de force, mais difficilement réductible à quelques concentrations dominantes. Les œuvres ne se laissent pas enfermer dans une grille trop simple. Elles associent les thèmes de manière diverse, parfois attendue, parfois plus singulière, et c'est précisément cette diversité qui fait apparaître la richesse latente du corpus.

Cette richesse doit naturellement être interprétée avec prudence. Le corpus reste sélectif, les thèmes ont été définis par le rédacteur du *Dictionnaire*, et des spécialistes de littérature russe pourraient légitimement discuter certains choix, certaines absences ou certaines attributions. Mais ces limites n'annulent pas l'intérêt de l'analyse. Elles rappellent seulement que celle-ci ne prétend pas épuiser la complexité des œuvres.

Son apport est plus modeste, mais réel : elle permet de rendre visible, par des moyens statistiques et graphiques, une pluralité thématique qui ne se réduit pas aisément à des catégories générales.

En définitive, l'absence de méta-thèmes clairement constitués devient elle-même un résultat.

Elle montre que le corpus étudié ne présente pas une structure thématique simple, immédiatement hiérarchisable ou aisément synthétisable. Loin d'appauvrir l'interprétation, ce constat confirme au contraire la fécondité du matériau étudié.

Même à travers un corpus nécessairement partiel, la littérature russe apparaît comme un ensemble riche, complexe, fortement différencié, dont la variété thématique résiste à toute réduction trop rapide.

Annexes

A1 Logiciels utilisés

- La matrice de données a été travaillée avec l'aide du logiciel Python dans l'environnement Anaconda et l'application Jupyter Notebook :


- Python : 3.12.2
- Conda : 23.1.0
- Jupyter_client : 8.8.0

Les principales bibliothèques utilisées sont pandas, numpy, matplotlib, scipy, scikit-learn, seaborn et networkx :

- pandas: 2.2.3
- numpy: 2.2.6
- matplotlib: 3.10.3
- scipy: 1.15.3
- scikit-learn: 1.8.0
- seaborn: 0.13.2
- networkx: 3.6.1
- prince: 0.17.0

Les valeurs de stress MDS présentées dans le document sont celles renvoyées par la version indiquée de scikit-learn.

A2 Nombre d'œuvres contenant un thème donné



Ce graphique complète la Figure 4 en présentant les 65 thèmes du corpus. Il confirme une distribution très asymétrique : quelques thèmes apparaissent dans un grand nombre d'œuvres, tandis que la majorité reste sous la moyenne de 9.60 œuvres par thème.

A3 Liste des œuvres du corpus


À la Veille	L'Affaire des Artamonov	Le Brigadier	Le Trois, le sept et l'as	Oblomov
À qui la faute?	L'Eternel mari	Le Cavalier d'airain	Le Verglas	Oncle Vania
Anna Karénine	L'Evêque	Le Chemin des tourments	Le Vertige	Pour le bien de la cause
Août Quatorze	L'Homme ne vit pas seulement de pain	Le Chevalier avare	Le Voyage de Saint-Pétersbourg à Moscou	Propriétaires d'autrefois
Babi Iar	L'Icône miraculeuse	Le Collier d'ambre	Les Ames mortes	Prose critique
Bonheur conjugal	L'Idiot	Le Convive de pierre	Les Bas-Fonds	Pères et fils
Boris Godounov	L'Orage	Le Coup de pistolet	Les Blaireaux	Pétersbourg
Cavalerie rouge	La Brouille des deux Ivan	Le Docteur Jivago	Les Carnets d'un Chasseur	Que faire?
Chez moi	La Cerisaie	Le Don Paisible	Les Cosaques	Roudine
Choses vécues et Pensées	La Chaussée de Volokolamsk	Le Duel	Les Douze	Résurrection
Chronique de famille	La Dame au petit chien	Le Démon mesquin	Les Douze chaises	Sachka
Crime et Châtiment	La Dame de pique	Le Gel au nez rouge	Les Démons	Souvenirs de la maison des morts
Cœur de chien	La Fille du capitaine	Le Grand filon	Les Ennemis	Sérioja
Dans les forêts	La Foire de Sorotchinsky	Le Joueur	Les Etoiles du jour	Tarass Boulba
Dans les Tranchées de Stalingrad	La Garde blanche	Le Journal d'un fou	Les Frères Karamazov	Tchelkach
Destin d'un homme	La Jeune Garde	Le Jugement	Les Golovliov	Terres défrichées
Doubrovski	La Maison de Matriona	Le Lieutenant Kijé	Les Jeunes années du petit-fils Bagrov	Terres vierges
Douce	La Mort d'Ivan Ilitch	Le Malheur d'avoir de l'esprit	Les Jours et les Nuits	Thomas Gordéiev
En gagnant mon pain	La Mouette	Le Manteau	Les Lointaines années	Tout passe
Enfance	La Mère	Le Maître et Marguerite	Les Nuits blanches	Un Été extraordinaire
Enfance et Adolescence	La Nuit de Mai ou la Noyée	Le Mineur	Les Pauvres gens	Un Homme véritable
Enfantés par la tempête	La Nuit de Noël	Le Monsieur de San Francisco	Les Petits-bourgeois	Un Héros de notre temps
Et l'Acier fut trempé	La Pauvre Lise	Le Musicien aveugle	Les Récits de Sébastopol	Un incident à la gare Krétchétoïka
Eugène Onéguine	La Perspective Nevski	Le Nez	Les Sept pendus	Un Mois à la campagne
Fondrières	La Provinciale	Le Pavillon des cancéreux	Les Trois sœurs	Une Banale histoire
Fumée	La Punaise	Le Portrait	Les Vivants et les morts	Une Ère inconnue commence
Guerre et Paix	La Quadrature du cercle	Le Premier cercle	Les Yeux tondus	Une Famille déchue
Hadji Mourat	La Salle 6	Le Prix des jours	Martha	Une Jeunesse inquiète

Histoire d'une ville	La Sonate à Kreutzer	Le Père Serge	Matinée d'un seigneur	Une journée d'Ivan Dénissovitich
Humiliés et Offensés	La Steppe	Le Quarante et unième	Maître et serviteur	Une place lucrative
Hyménée	La Vie d'Arséniev	Le Ravin	Mes Universités	Une Terrible Vengeance
Il est un blanc navire	La Vie de Klim Samguine	Le Révizor	Mistère-Bouffe	Vassa Géléznova
Ivanov	La Vie de l'Archiprêtre Avvakum	Le Silence	Mozart et Saliéri	Vii
Kira	La Ville de Villegrad	Le Songe de Makar	Nid de Gentilshommes	
L'Adolescent	Lady Macbeth du district de Mtsensk	Le Sous-sol	Nous autres	


A4 Dendrogramme complet des œuvres du corpus

Le dendrogramme complet est fourni à titre documentaire ; sa densité rend son interprétation directe difficile.

Dendrogramme des oeuvres
(distance = 'jaccard' / méthode : 'average')
- 173 oeuvres - 14878 comparaisons -



A5 Frise chronologique des auteurs du corpus



Chaque segment horizontal représente l'intervalle compris entre la naissance et le décès de l'auteur. Les auteurs sont classés par date croissante de décès, et les lignes verticales matérialisent les principales limites chronologiques utilisées dans l'étude. Cette figure décrit la succession des générations d'auteurs, non la période exacte de composition de leurs œuvres.

A6 Technique MDS (Multi-Dimensional Scaling)

Le MDS (Multi-Dimensional Scaling) est une technique d'apprentissage automatique non supervisée qui permet de visualiser dans un espace en faible dimension, tel qu'un plan par exemple, les relations entre des points situés dans un espace de grande dimension, avec pour objectif de placer les points de telle sorte que leurs distances dans le plan reproduisent aussi fidèlement que possible les dissimilarités d'origine.

- De façon classique, le MDS agit de la façon suivante :

- Si les dissimilarités entre deux objets quelconques i et j sont données par une matrice de distances D_{ij} , le MDS recherche pour ces deux objets deux coordonnées x_i et x_j dans un espace de faible dimension (un plan par exemple), de distance euclidienne d_{ij} , de façon que soit minimisée une « fonction de stress », qui peut être définie, selon les conventions, sous forme « brute » ou « normalisée ».

Dans le présent document, les valeurs reportées sont celles renvoyées par `scikit-learn` : `1.8.0` ; elles sont utilisées uniquement pour comparer plusieurs initialisations du même MDS.

- La recherche des coordonnées x_i et x_j (si l'on se place dans un plan), se fait par approximations successives en utilisant un algorithme spécialement dédié à cette opération : algorithme SMACOF (Scaling by MAjorizing a COmplicated Function) qui calcule le stress à partir d'une configuration initiale des points, placés aléatoirement dans le plan pour initialiser le processus, puis améliore progressivement cette configuration, par une transformation dite « de Guttman », jusqu'à parvenir à une configuration où le calcul itératif du stress est convergent.
- L'algorithme peut être exécuté à partir de plusieurs configurations initiales aléatoires dans le plan, conduisant à plusieurs valeurs de convergence du stress.

La configuration plane adoptée est alors celle où la fonction de stress est minimale.

- Pour ce faire, l'algorithme utilise un paramètre noté `n_init`, qui est le nombre de fois où l'algorithme sera exécuté avec différentes initialisations de points dans le plan.
- En principe, plus souvent l'algorithme est exécuté à partir de positions initiales différentes, plus on augmente les chances de tomber sur une meilleure solution finale, puisque l'on teste davantage de configurations initiales.
- Toutefois, le coût du calcul induit par une augmentation de `n_init` ne se traduit pas forcément par une amélioration visuelle quantifiable.

A7 Détail de construction de la modularité

Cette annexe vise à expliciter pourquoi l'algorithme de modularité ne fusionne pas nécessairement les thèmes les plus fortement co-occurents, mais ceux dont la fusion augmente le plus la modularité.

Construction

La matrice de co-occurrence sur laquelle le graphe est construit contient 65×65 cellules de valeurs C_{ij} , où :

- C_{ij} : entier positif ou nul
- C_{ii} : fréquence absolue du thème i dans le corpus
- $C_{i \neq j}$: nombre de co-occurrences du couple (i, j) dans le corpus

De façon formelle, le graphe généré à l'aide du package `networkx` construit une arête entre deux nœuds si :

- les deux nœuds sont différents : on veut construire un graphe de relations entre les thèmes et faire boucler un thème sur lui-même n'aurait pas de sens.
 $\Rightarrow$ La diagonale de la matrice n'est pas transformée en arêtes du graphe.
- le poids de l'arête est supérieur ou égal au seuil retenu : le nombre de co-occurrences entre deux thèmes doit atteindre le niveau conventionnel choisi pour le filtrage. Il ne s'agit pas ici d'un seuil de significativité statistique.
 $\Rightarrow$ Les couples dont le nombre est inférieur au seuil ne sont pas transformés en arêtes du graphe.

Le graphe est donc construit à partir d'une matrice d'adjacence (A_{ij}) dérivée de la matrice de co-occurrence (C_{ij}) par :

$$A_{ij} = \begin{cases} C_{ij} & \text{si une arête existe} \\ 0 & \text{sinon} \end{cases}$$

En particulier : $A_{ii} = 0$

Par exemple considérons 3 thèmes T_1, T_2, T_3 et un seuil s :

Si : matrice de co-occurrences
(C_{ij})

$$\begin{matrix} & \begin{matrix} T_1 & T_2 & T_3 \end{matrix} \\ \begin{matrix} T_1 \\ T_2 \\ T_3 \end{matrix} & \begin{pmatrix} a & d \geq s & e < s \\ d \geq s & b & f \geq s \\ e < s & f \geq s & c \end{pmatrix} \end{matrix}$$

$\Rightarrow$

Alors : matrice d'adjacence
(A_{ij})

$$\begin{matrix} & \begin{matrix} T_1 & T_2 & T_3 \end{matrix} \\ \begin{matrix} T_1 \\ T_2 \\ T_3 \end{matrix} & \begin{pmatrix} 0 & d & 0 \\ d & 0 & f \\ 0 & f & 0 \end{pmatrix} \end{matrix}$$

Le graphe contient les arêtes
 $T_1 \leftrightarrow T_2$ et $T_2 \leftrightarrow T_3$

Pour un graphe pondéré, la modularité est :

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(i, j)$$

où :

- Q = modularité totale
- A_{ij} = poids réel entre i et j lorsqu'une arête existe
- k_i = degré pondéré du nœud i , calculé par :

$$k_i = \sum_j A_{ij}$$

Autrement dit la somme des poids de toutes les arêtes qui partent du nœud i . Le degré pondéré mesure donc la force totale des connexions du thème.

- m = poids total du graphe, calculé par :

$$m = \frac{1}{2} \sum_{i,j} A_{ij}$$

Autrement dit la somme de tous les poids des arêtes, avec un facteur $\frac{1}{2}$ qui évite de compter deux fois chaque arête puisque : $A_{ij} = A_{ji}$ (dans le réseau qui est non orienté).

- δ est une fonction *delta* qui vaut :
 - $\delta(i, j) = 1$ si i et j sont dans la même communauté
 - $\delta(i, j) = 0$ sinon

Donc :

$$\frac{k_i k_j}{2m} = \frac{\sum_j A_{ij} \times \sum_i A_{ji}}{\sum_{i,j} A_{ij}} = \frac{\text{somme des poids en ligne} \times \text{somme des poids en colonne}}{\text{somme de tous les poids de la matrice d'adjacence}}$$

C'est le poids attendu entre les nœuds i et j dans un réseau aléatoire – construit sur (A_{ij}) – qui aurait les mêmes degrés pondérés k_i et k_j .

La différence :

$$A_{ij} - \frac{k_i k_j}{2m}$$

compare le poids réel au poids attendu et cette valeur est prise en compte si les deux nœuds sont dans la même communauté.

L'algorithme commence par constituer autant de communautés qu'il existe de nœuds dans le graphe filtré, chaque nœud formant initialement sa propre communauté. Ainsi, pour le seuil 5 retenu dans l'étude, le calcul commence avec 22 communautés correspondant aux 22 thèmes actifs.

Puis il examine toutes les paires de thèmes qui sont reliées dans le graphe par au moins une arête, calcule de combien la modularité augmenterait si l'on fusionnait ces deux communautés, et choisit la fusion qui procure le plus grand gain de modularité ΔQ .

Si deux fusions procurent exactement le même gain, l'algorithme applique une règle de départage :

- les gains ΔQ sont stockés dans une structure de type tas ("heap"),
- lorsqu'il y a égalité, les égalités sont départagées par des règles internes d'ordre des identifiants ; ce choix n'a pas de signification statistique ou littéraire.
- il n'y a donc pas de signification mathématique profonde au choix effectué en cas d'égalité parfaite.

Lors de la partition initiale en 65 communautés, deux thèmes différents ne sont évidemment pas dans la même communauté et $\delta(i, j \neq i) = 0$.

- les seuls termes qui subsistent dans la formule sont ceux pour lesquels $i = j$ et dans ce cas la modularité initiale devient donc :

$$Q_0 = \frac{1}{2m} \sum_i \left(\underbrace{A_{ii}}_{=0} - \frac{k_i^2}{2m} \right) = -\frac{1}{(2m)^2} \sum_i (k_i^2)$$

- la modularité initiale est alors négative.

Pour l'exemple précédent :

$$(A_{ij}) = \begin{pmatrix} 0 & d & 0 \\ d & 0 & f \\ 0 & f & 0 \end{pmatrix} \Rightarrow \begin{cases} k_1 = d \\ k_2 = d + f \\ k_3 = f \end{cases} \Rightarrow m = d + f$$

$$Q_0 = -\frac{1}{4(d+f)^2} (d^2 + (d+f)^2 + f^2) = -\frac{d^2 + df + f^2}{2(d+f)^2}$$

Dans cet exemple à 3 thèmes et 2 arêtes $T_1 \leftrightarrow T_2$ et $T_2 \leftrightarrow T_3$, l'algorithme va tester le regroupement de T_1 et T_2 , et le regroupement de T_2 et T_3 :

Si l'on regroupe T_1 et T_2 :

- le graphe reste le même : la matrice (A_{ij}) ne change pas,
- les degrés pondérés k_i restent les mêmes,
- c'est seulement la fonction δ qui change : après fusion, T_1 et T_2 appartiennent à la même communauté, donc :

$$\delta(T_1, T_2) = \delta(T_2, T_1) = 1, \quad \delta(T_1, T_3) = \delta(T_3, T_1) = 0, \quad \delta(T_2, T_3) = \delta(T_3, T_2) = 0$$

La nouvelle modularité Q_{12} peut se recalculer ici par la formule initiale (bien qu'il existe des méthodes plus rapides) :

$$\begin{aligned} Q_{12} &= \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(i, j) \\ &= \frac{1}{2(d+f)} \left\{ \underbrace{\left[\left(0 - \frac{d^2}{2(d+f)} \right) \times 1 \right]}_{(1,1)} + \underbrace{\left[\left(d - \frac{d(d+f)}{2(d+f)} \right) \times 1 \right]}_{(1,2)} + \underbrace{\left[\left(0 - \frac{df}{2(d+f)} \right) \times 0 \right]}_{(1,3)} \right. \\ &\quad + \underbrace{\left[\left(d - \frac{d(d+f)}{2(d+f)} \right) \times 1 \right]}_{(2,1)} + \underbrace{\left[\left(0 - \frac{(d+f)^2}{2(d+f)} \right) \times 1 \right]}_{(2,2)} + \underbrace{\left[\left(f - \frac{f(d+f)}{2(d+f)} \right) \times 0 \right]}_{(2,3)} \\ &\quad \left. + \underbrace{\left[\left(0 - \frac{fd}{2(d+f)} \right) \times 0 \right]}_{(3,1)} + \underbrace{\left[\left(f - \frac{f(d+f)}{2(d+f)} \right) \times 0 \right]}_{(3,2)} + \underbrace{\left[\left(0 - \frac{f^2}{2(d+f)} \right) \times 1 \right]}_{(3,3)} \right\} \\ &= \frac{1}{2(d+f)} \left\{ -\left[\frac{d^2}{2(d+f)} \right] + \left[\frac{d}{2} \right] + \left[\frac{d}{2} \right] - \left[\frac{d+f}{2} \right] - \left[\frac{f^2}{2(d+f)} \right] \right\} \\ &= \frac{1}{2(d+f)} \left\{ -\frac{d^2}{2(d+f)} + \frac{d-f}{2} - \frac{f^2}{2(d+f)} \right\} \\ &= \frac{1}{2(d+f)^2} \left\{ -\frac{d^2}{2} + \frac{(d-f)(d+f)}{2} - \frac{f^2}{2} \right\} \\ &= \frac{1}{2(d+f)^2} \{-f^2\} \\ &= -\frac{f^2}{2(d+f)^2} \end{aligned}$$

Le gain de modularité obtenu en fusionnant T_1 et T_2 est :

$$\Delta Q_{12} = Q_{12} - Q_0 = -\frac{f^2}{2(d+f)^2} + \frac{d^2 + df + f^2}{2(d+f)^2} = \frac{d^2 + df}{2(d+f)^2} = \frac{d}{2(d+f)}$$

On trouverait de même que le gain de modularité obtenu en fusionnant T_2 et T_3 est :

$$\Delta Q_{23} = \frac{f}{2(d+f)}$$

Par conséquent, l'algorithme choisirait de regrouper T_1 et T_2 si $d > f$ et de regrouper T_2 et T_3 si $f > d$ (il choisirait l'un des deux cas si $d = f$).

Résumé

Si l'on fusionne les communautés contenant T_1 et T_2 , le graphe lui-même n'est pas modifié : la matrice d'adjacence A_{ij} , les degrés pondérés k_i et le poids total m restent identiques. Ce qui change est uniquement la partition des nœuds, donc la fonction δ , qui vaut désormais 1 pour les couples (T_1, T_2) et (T_2, T_1) . Dans cet exemple, le gain de modularité associé à la fusion de T_1 et T_2 vaut :

$$\Delta Q_{12} = \frac{d}{2(d+f)}$$

La fusion est donc d'autant plus favorable que le poids d de l'arête $T_1 \leftrightarrow T_2$ est élevé relativement au poids total du graphe.

Précisions

Dans le cas particulier où $d = f$, les deux fusions possibles $T_1 + T_2$ et $T_2 + T_3$ procurent exactement le même gain de modularité. Elles sont donc équivalentes du point de vue mathématique : aucune des deux ne révèle une relation plus forte ou une structure plus pertinente dans le graphe. L'algorithme doit cependant effectuer un choix pour poursuivre le processus de fusion.

Dans `networkx`, l'algorithme commence avec une communauté par nœud, puis fusionne à chaque étape la paire de communautés qui conduit au plus grand gain de modularité. Au départ, comme chaque thème constitue sa propre communauté, l'identifiant de communauté est simplement l'identifiant du nœud correspondant : la communauté $\{T_1\}$ est associée à l'identifiant T_1 , la communauté $\{T_2\}$ à l'identifiant T_2 , etc.

En cas d'égalité parfaite entre plusieurs gains de modularité, le choix n'est plus déterminé par la modularité elle-même, mais par une règle de départage interne à l'implémentation.

Dans `networkx`, les fusions candidates sont stockées dans une structure de priorité, et les égalités sont départagées en choisissant la paire dont le plus petit identifiant de communauté est classé en premier. Le symbole $<$, lorsqu'on écrit par exemple $T_1 < T_2 < T_3$, ne signifie donc pas que les thèmes possèdent une grandeur numérique ou statistique. Il signifie seulement que l'ordre informatique de comparaison des identifiants place T_1 avant T_2 , et T_2 avant T_3 .

Ainsi, si l'ordre informatique des identifiants place T_1 avant T_2 , puis T_2 avant T_3 , la paire (T_1, T_2) sera choisie avant la paire (T_2, T_3) , puisque l'identifiant minimal de la première paire est T_1 , tandis que l'identifiant minimal de la seconde est T_2 . Si les thèmes sont désignés par des labels textuels, cet ordre peut correspondre à l'ordre lexicographique des chaînes de caractères, c'est-à-dire à un ordre proche de l'ordre alphabétique ; mais il ne faut pas l'interpréter comme un critère thématique ou statistique. Les majuscules, les minuscules, les accents ou certains signes peuvent d'ailleurs modifier cet ordre informatique. Il s'agit seulement d'une convention permettant de départager deux fusions mathématiquement équivalentes.

A8 Analyse de sensibilité pour le seuil du réseau

Les tableaux ci-dessous ne listent que les thèmes conservés dans le réseau pour chaque seuil ; les thèmes isolés après filtrage ne sont pas affichés.

Liste des communautés par seuil

seuil = 3					
communauté_1	communauté_2	communauté_3	communauté_4	communauté_5	communauté_6
thèmes	thèmes	thèmes	thèmes	thèmes	thèmes
Amour	Art	Apprentissage	Argent	Communisme	Fantastique
Bonheur	Camps	Fonctionnaires	Dieu	Guerre	Pouvoir
Campagne	Capitalisme	Nature	Humanisme	Héros	Remords
Délire-Folie	Liberté	Noblesse	Marchands	Patrie	Ville
Ennui	Médiocrité	Religion	Mort	Responsabilité	
Femme	Société	Servage	Solitude		
Individu	Souffrance	Traditions			
Intelligentsia	Travail				
Justice					
Mal					
Mariage					
Misère					
Occident					
Paysans					
Peuple					
Province					
Russie					
Révolution					
Rêve					
Socialisme					
Violence					

seuil = 4					
communauté_1	communauté_2	communauté_3	communauté_4	communauté_5	communauté_6
thèmes	thèmes	thèmes	thèmes	thèmes	thèmes
Amour	Communisme	Noblesse	Pouvoir	Fantastique	Capitalisme
Apprentissage	Guerre	Occident	Remords	Ville	Société
Argent	Héros	Russie			
Bonheur	Intelligentsia	Servage			
Campagne	Patrie	Traditions			
Dieu	Responsabilité				
Ennui	Révolution				
Femme					
Humanisme					
Individu					
Mal					
Mort					
Nature					
Peuple					
Rêve					
Solitude					

seuil = 5		
communauté_1	communauté_2	communauté_3
thèmes	thèmes	thèmes
Amour	Communisme	Noblesse
Argent	Guerre	Occident
Bonheur	Héros	Servage
Campagne	Patrie	Traditions
Dieu	Révolution	
Femme		
Intelligentsia		
Mal		
Mort		
Nature		
Pouvoir		
Rêve		
Solitude		

seuil = 6		
communauté_1	communauté_2	communauté_3
thèmes	thèmes	thèmes

Amour	Communisme	Noblesse
Argent	Guerre	Servage
Bonheur	Patrie	
Dieu		
Femme		
Intelligentsia		
Mort		
Occident		
Révolution		
Traditions		

seuil = 7		
communauté_1	communauté_2	communauté_3
thèmes	thèmes	thèmes

Amour	Noblesse	Guerre
Argent	Servage	Patrie
Bonheur		
Femme		
Mort		
Occident		
Traditions		

seuil = 8	
communauté_1	communauté_2
thèmes	thèmes

Amour	Guerre
Argent	Patrie
Bonheur	
Femme	
Mort	
Noblesse	

A9 Matrice finale de profil thématique pour l'AC

Author	Amour	Apprentissage	Argent	Bonheur	Fantastique	Femme	Guerre	Intelligentisia	Liberté	Mort	Nature	Noblesse	Occident	Patrie	Révolution	Société	Souffrance	Traditions	Ville
A.OSTROVSKI	1	0	1	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1	0
A.TOLSTOÏ	1	0	0	0	0	0	1	1	0	0	0	0	0	0	1	0	0	0	0
AKSAKOV	0	1	0	0	0	0	0	0	0	0	1	1	0	0	0	0	0	1	0
AVVAKUM	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	0
AÏTMATOV	0	1	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	1	0
BABEL	0	0	0	0	0	0	1	0	0	0	0	0	0	0	1	0	0	0	0
BERGHOLTS	0	0	0	0	0	0	1	0	0	0	0	0	0	1	0	1	0	0	0
BIELY	0	0	0	0	1	0	0	0	0	0	0	0	1	0	1	0	0	0	1
BLOK	0	0	0	0	0	0	0	1	0	0	0	0	1	0	0	0	0	0	0
BOUNINE	1	0	0	0	0	1	0	0	0	1	1	0	0	0	0	0	0	0	0
CHOLOKHOV	1	0	0	0	0	1	1	0	0	0	0	0	0	0	1	0	0	0	0
DOSTOÏEVSKI	9	1	5	1	0	7	0	0	1	3	0	1	2	0	0	0	2	0	2
DOUDINTSEV	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0
FADÉÏEV	0	0	0	0	0	0	1	0	0	0	0	0	0	1	0	0	0	0	0
FEDINE	1	0	0	0	0	0	1	0	0	0	0	0	0	1	0	0	0	0	0
GOGOL	1	0	1	0	0	0	0	0	1	0	0	1	0	0	0	0	0	0	0
GONTCHAROV	1	0	0	0	0	2	0	0	0	0	0	0	0	0	0	0	0	2	0
GORKI	1	0	2	0	0	2	0	0	0	0	0	0	0	0	1	3	0	0	0
GRIBOÏEDOV	1	0	0	0	0	0	0	0	0	0	0	1	1	0	0	0	0	0	0
GUINZBOURG	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	1	1	0	0
HERZEN	0	0	0	0	0	0	0	1	0	0	0	1	1	0	0	0	0	0	0
KOUPRINE	0	0	0	0	0	1	0	0	0	1	0	0	0	0	0	0	0	0	0
KOUZNETSOV	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
L.TOLSTOÏ	4	0	0	4	0	3	2	0	1	3	1	2	1	1	0	0	0	0	1
LEONOV	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	0	1	1
LESKOV	0	0	0	0	0	1	0	0	0	0	0	1	0	0	0	0	0	1	0
MELNIKOV-PETCHERSKI	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0

N.OSTROVSKI	0	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0
PASTERNAK	1	0	0	0	0	1	1	0	0	0	1	0	0	0	1	0	0	0	0
POLEVOÏ	0	0	0	0	0	0	1	0	0	0	0	0	0	1	0	0	0	0	0
POUCHKINE	3	1	1	0	1	2	0	0	0	1	2	1	0	0	1	0	0	0	1
SALTYKOV-CHTCHEDRINE	0	0	1	0	1	0	0	0	0	0	0	1	0	0	0	0	0	0	1
SOLJENITSYNE	1	0	0	0	0	0	1	0	2	1	0	0	0	0	0	2	3	0	0
SOLOGOUB	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
TCHEKHOV	1	0	1	0	0	3	0	3	0	1	0	0	0	0	0	0	0	0	0
TCHERNYCHEVSKI	1	0	0	1	0	1	0	1	0	0	0	0	0	0	1	0	0	0	0
TENDRIAKOV	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
TOURGUENIEV	3	0	0	2	0	5	0	2	0	2	1	3	2	0	1	0	0	2	0
V.NEKRASSOV	1	0	0	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0	0
ZAMIATINE	1	0	0	1	1	0	0	0	1	0	0	0	0	0	0	0	0	0	0

A10 Contributions et $\cos^2$ en analyse des correspondances

On supposera connues les deux notions suivantes :

- Coordonnée factorielle : la coordonnée factorielle indique la position signée d'un auteur ou d'un thème sur un axe de l'AC et mesure ainsi la direction et l'importance de son écart au profil moyen selon la dimension représentée par cet axe.
- Inertie d'un tableau : l'inertie d'un tableau mesure la dispersion globale des profils autour du profil moyen, c'est-à-dire l'importance des écarts entre les associations observées et celles qui seraient attendues en situation d'indépendance.

Idée essentielle

La *contribution* indique dans quelle mesure un auteur ou un thème construit un axe factoriel. Le $\cos^2$ indique dans quelle mesure cet auteur ou ce thème est correctement représenté sur l'axe ou sur le plan affiché :

Indicateur	Question posée	Lecture principale
Contribution	Quels auteurs ou quels thèmes construisent principalement les axes ?	Importance du point dans la structure de l'axe
$\cos^2$	Quels auteurs ou quels thèmes sont correctement représentés sur le graphique ?	Fiabilité de la position visible sur le graphique

Principe général

L'analyse des correspondances (AC) représente les lignes et les colonnes d'un tableau de données sous la forme de points dans un espace factoriel.

Dans la présente étude, les lignes correspondent aux auteurs et les colonnes aux thèmes.

La position d'un auteur dépend de son profil thématique, c'est-à-dire de la répartition des thèmes dans les œuvres qui lui sont attribuées. Réciproquement, la position d'un thème dépend de sa répartition entre les différents auteurs.

L'AC construit plusieurs axes factoriels successifs. Chaque axe restitue une partie de l'inertie totale du tableau, autrement dit une partie des écarts entre les profils observés et le profil moyen. Les premiers axes sont ceux qui résument la plus grande part de cette inertie.

Deux indicateurs sont nécessaires pour interpréter correctement les graphiques factoriels :

- les *contributions*, qui identifient les points participant le plus à la construction des axes, et
- les $\cos^2$, qui mesurent la qualité de représentation de chaque point sur les axes ou sur le plan factoriel affiché.

Définition mathématique des contributions

La contribution d'un point mesure la part qu'il prend dans la construction d'un axe factoriel.

Pour un auteur i et un axe factoriel α :

$$Ctr_{i\alpha} = \frac{r_i F_{i\alpha}^2}{\lambda_\alpha}$$

Pour un thème j et un axe factoriel α , la formule est strictement analogue :

$$Ctr_{j\alpha} = \frac{c_j G_{j\alpha}^2}{\lambda_\alpha}$$

Où:

r_i, c_j	masse de l'auteur i (ou du thème j), c'est-à-dire son poids relatif dans le tableau
$F_{i\alpha}, G_{j\alpha}$	coordonnée factorielle de l'auteur i (ou du thème j) sur l'axe α
$F_{i\alpha}^2, G_{j\alpha}^2$	carré de cette coordonnée : le signe disparaît et seul l'éloignement sur l'axe est pris en compte
λ_α	valeur propre de l'axe α , donc inertie totale expliquée par cet axe

L'inertie d'un axe est la somme des inerties apportées par tous les points (auteurs i ou thèmes j) :

$$\lambda_\alpha = \sum_i r_i F_{i\alpha}^2 = \sum_j c_j G_{j\alpha}^2$$

Ainsi, pour chaque axe, la somme des contributions de tous les points (auteurs i ou thèmes j) est égale à 1, ou à 100 % lorsqu'elles sont exprimées en pourcentage.

Interprétation de la contribution

Une contribution élevée signifie que le point joue un rôle important dans la définition de l'axe.

Par exemple, un auteur ayant une forte contribution à l'axe 1 participe fortement à l'opposition représentée par cet axe : son profil thématique s'écarte du profil moyen dans une direction qui structure l'analyse.

La contribution ne donne toutefois pas le sens de cette opposition. Elle est calculée à partir du carré de la coordonnée et reste donc positive. Pour déterminer le côté de l'axe auquel appartient le point, il faut revenir au signe de sa coordonnée :

- coordonnée positive :côté positif de l'axe ;
- coordonnée négative :côté négatif de l'axe.

La contribution indique ainsi l'importance du point dans la construction de l'axe ; la coordonnée indique la direction dans laquelle il intervient.

Contribution moyenne attendue

Lorsqu'une analyse comprend n points (auteurs i ou thèmes j), la contribution moyenne théorique d'un point à un axe est :

$$\frac{1}{n}, \text{ ou } \frac{100}{n} (\%)$$

Ainsi, avec 40 auteurs, la contribution moyenne attendue par auteur est :

$$\frac{100}{40} = 2.5 \%$$

Avec 19 thèmes, la contribution moyenne attendue par thème est :

$$\frac{100}{19} \approx 5.26 \%$$

Contribution au plan factoriel 1-2

Dans la présente étude, la contribution d'un point i au plan formé par les axes 1 et 2 est calculée comme une moyenne des contributions aux deux axes, pondérée par leurs inerties respectives :

$$\text{Ctr}_{i,(1,2)} = \frac{\lambda_1 \text{Ctr}_{i,1} + \lambda_2 \text{Ctr}_{i,2}}{\lambda_1 + \lambda_2}$$

où λ_1 et λ_2 désignent les valeurs propres associées aux deux premiers axes. Cette pondération donne davantage de poids à l'axe qui représente la plus grande part de l'inertie du tableau.

En revenant à la définition des contributions, on peut écrire :

$$\text{Ctr}_{i,(1,2)} = \frac{\lambda_1 \frac{r_i F_{i1}^2}{\lambda_1} + \lambda_2 \frac{r_i F_{i2}^2}{\lambda_2}}{\lambda_1 + \lambda_2} = \frac{r_i F_{i1}^2 + r_i F_{i2}^2}{\lambda_1 + \lambda_2}$$

La somme des contributions de tous les points au plan est alors :

$$\sum_i \text{Ctr}_{i,(1,2)} = \frac{1}{\lambda_1 + \lambda_2} \left(\underbrace{\sum_i r_i F_{i1}^2}_{=\lambda_1} + \underbrace{\sum_i r_i F_{i2}^2}_{=\lambda_2} \right) = 1$$

Par conséquent, la somme des contributions au plan 1 – 2 est donc égale à 1, soit 100 % lorsqu'elles sont exprimées en pourcentage.

L'addition directe des contributions aux axes 1 et 2, $\text{Ctr}_{i,1} + \text{Ctr}_{i,2}$, constituerait un autre indicateur possible, mais elle totaliserait 200 % pour l'ensemble des points. Elle ne correspond pas au calcul retenu dans la présente analyse.

Définition géométrique du $\cos^2$

Le $\cos^2$ mesure la qualité de représentation d'un point sur un axe factoriel.

Pour un auteur i et un axe factoriel α :

$$\cos^2_{i\alpha} = \frac{F_{i\alpha}^2}{d_i^2}$$

Pour un thème j et un axe factoriel α , la formule est strictement analogue :

$$\cos^2_{j\alpha} = \frac{G_{j\alpha}^2}{d_j^2}$$

Où d_i^2 (d_j^2) est le carré de la distance totale du point à l'origine dans l'espace factoriel complet :

$$d_i^2 = \sum_{\alpha} F_{i\alpha}^2 \quad \text{et} \quad d_j^2 = \sum_{\alpha} G_{j\alpha}^2$$

Valeurs possibles du $\cos^2$

Un $\cos^2$ étant nécessairement compris entre 0 et 1, on a les interprétations suivantes :

Proche de 1	l'axe représente presque entièrement la direction du point
Valeur intermédiaire	l'axe ne restitue qu'une partie de la position du point
Proche de 0	l'axe représente très peu la position réelle du point

Par exemple, un $\cos^2$ égal à 0.70 sur l'axe 1 signifie que cet axe restitue 70 % du carré de la distance factorielle du point à l'origine, autrement dit 70 % de l'inertie propre de ce point.

Pour un point donné, la somme de ses $\cos^2$ sur l'ensemble des axes est égale à 1 :

$$\sum_{\alpha} \cos^2_{i\alpha} = 1$$

cos² sur plan factoriel 1 – 2

La qualité de représentation d'un point sur le plan formé par les deux premiers axes est la somme des cos² relatifs à ces deux axes :

$$\cos^2_{i,(1,2)} = \cos^2_{i1} + \cos^2_{i2}$$

En remplaçant chaque cos² par sa définition, on obtient la formule complète (pour un auteur par exemple) :

$$\cos^2_{i,(1,2)} = \frac{F_{i1}^2 + F_{i2}^2}{d_i^2}$$

➤ où F_{i1}^2 (F_{i2}^2) sont les carrés des coordonnées factorielles.

Par exemple, si un auteur i a pour carrés de ses coordonnées factorielles $F_{i1}^2 = 0.32$ et $F_{i2}^2 = 0.18$, et si le carré de sa distance à l'origine vaut $d_i^2 = 0.80$, son cos² sur le plan 1 – 2 vaudra :

$$\cos^2_{i,(1,2)} = \frac{0.32 + 0.18}{0.80} = 0.625$$

Ce qui signifie que le graphique restitue 62.5 % du carré de la distance factorielle totale de cet auteur, ou 62.5 % de son inertie propre ; les 37.5 % restants sont portés par les axes suivants.

Utilité des cos²

Un graphique factoriel est une projection d'un espace comportant plusieurs dimensions sur un plan à deux dimensions. Toute projection entraîne une perte d'information. Les cos² permettent d'évaluer cette perte pour chaque auteur et chaque thème séparément.

Un point ayant un cos² élevé sur le plan 1 – 2 peut être interprété directement à partir de sa position graphique : sa direction, son éloignement du centre et ses proximités avec les autres points de même nature (auteurs entre eux ou thèmes entre eux) sont relativement bien restitués.

À l'inverse, la position d'un point ayant un faible cos² doit être interprétée avec prudence. Deux points peuvent sembler proches sur le plan 1 – 2 alors que cette proximité résulte en partie de la projection et disparaîtrait si les dimensions suivantes étaient prises en compte.

Dans cette étude, un cos² sur le plan 1 – 2 supérieur ou égal à 0.25 a été retenu comme critère pratique d'interprétabilité. Ce seuil signifie qu'au moins 25 % du carré de la distance factorielle du point est représentée par les deux premiers axes. Il s'agit d'un choix méthodologique, non d'une règle universelle.

Résumé des combinaisons possibles

Contribution	Cos ²	Interprétation
Élevée	Élevé	Point structurant et correctement représenté : situation la plus favorable pour l'interprétation.
Élevée	Faible	Point important pour l'axe, mais dont la position complète est insuffisamment restituée sur le plan.
Faible	Élevé	Point bien représenté, dont la position peut être décrite, mais qui joue un rôle secondaire dans la construction de l'axe.
Faible	Faible	Point peu structurant et mal représenté : il fournit peu d'éléments fiables pour commenter le plan 1-2.

Précaution importante : Une proximité entre un auteur et un thème sur un plan d'AC ne s'interprète pas comme une corrélation géométrique simple entre deux vecteurs. Elle doit être replacée dans la logique des profils, des contributions, des $\cos^2$ et du tableau de contingence d'origine.